

Singulab — 集団構成パラメータと創発の関係を観察する

- Singulab
- 思想と背景
 - 何を観察したかったか
 - 提出版に至るまでの大きな路線変更
 - 参考実装と何が違うのか
 - 3 階層モデル
 - なぜハッカソンに出すのか
- システム構成
 - 全体アーキテクチャ
 - ハードウェア
 - 採用 LLM
 - なぜ Uncensored(abliterated)を選んだか
 - 5 種類のログ + エコー検証パイプライン
 - シナリオ駆動
- 検証結果
 - 「会話の質」を巡る発見と段階的改善
 - 5 体ランの結果(Phase 5 主役)
 - 比較軸 1 — 規模を変えると何が変わるか(参考データ:旧 4 象限)
 - 比較軸 2 — 創発イベントを変えると何が変わるか(Phase 5 中心)
 - 解釈
- 創発観察
 - 4.1 イベント反応の多様化(MBTI × 創発イベントの効果)
 - 4.2 沈黙 — 規模が押し付ける役割分化(5 体でも観測)
 - 4.3 エコー(完全コピペ)の消滅
 - 4.4 受信メッセージへの応答(reflection)の正常化
 - 4.5 観察できなかったもの(Phase 5 改良版でも未到達)
 - 4.6 観察の限界(率直に)
 - 4.7 最大の発見(率直)
- 頑張った点
 - 5.1 比較設計の枠組み
 - 5.2 失敗・没案
 - 5.3 技術的挑戦
- 未解決課題
 - 6.1 試行回数の不足(N=1 試行のまま)

- 6.2 100 体 × Qwen3 34B の結果が未到着
- 6.3 旧 4 象限結果のエコー疑惑(再評価が必要)
- 6.4 観察できなかった創発(嘘 / 通貨 / 反乱 / 明確な派閥)
- 6.5 創発指標の主観性
- 6.6 MBTI が創発に効くかは未確認(検証コスト)
- 6.7 6GB VRAM 由来の制約
- 6.8 動画の網羅性
- 6.9 ペルソナのバイアス
- 6.10 「もし API ハイブリッドが許されたら」
- 今後の展望
 - 他シナリオへの拡張
 - 提出後すぐ着手するもの(優先順)
 - モデル拡張
 - 規模拡張
 - 公開プラン

Singulab

集団構成パラメータと創発の関係を観察する

LLM 多体シミュレーションによる仮説検証レポート
Phase 5(MBTI ペルソナ + 創発イベント + エコー対策)

Kai、タコ

github.com/Kai-85-git/singulab

2026-04-30 v1.0

思想と背景

何を観察したかったか

本プロジェクトの問いは一つ。

エージェント集団の構成(MBTI / 年齢 / 性別 / 国籍)と、それを取り囲む 2 階の環境(場の構造・突発イベント)を変えると、創発(嘘・派閥・通貨・反乱・合意形成・発言権)はどう変わるか。

LLM ベンチマークでも、シミュレーション基盤の披露でもない。比較実験それ自体が主役である。同じシナリオを、構成だけ差し替えて何度も走らせ、創発の差を観察する。

ハッカソン提出版(Phase 5)では、2026-04-29 のミーティングで合意した方針に沿って:

- 集団サイズ: 5 人 / 100 人の 2 通り(部署分け・階層化はあえてしない)
- 創発イベント: 宇宙人 / 無重力(プラン B = 既存のシナリオでは結果が予想できる「火事」型を避け、未知の発火点を観察する)
- ペルソナ: MBTI + 年齢 + 性別 + 国籍ランダム(役職や名前は 意図的に与えない)

の 4 軸で観察を行った。

提出版に至るまでの大きな路線変更

初稿(Phase 4-A、2026-04-30 早朝時点)は 旧 4 象限(都心/地方 × 大企業/スタートアップ × 景気)で本番ランを完走させ PDF を生成していた。しかし messages.jsonl を実データ確認したところ、全エージェントが一字一句同じ定型句を吐く問題(echo_max=1.000、4 シナリオすべて)が見つかった。これを「会話していない」と判断し、4 段階の対策を上から順に積み上げて品質を回復した。

段階	対策	主要指標の変化	検証ログ
Phase 4-A	旧 4 象限の本番ラン完走	echo_max=1.000、 reflection_mean=0.705	Phase4-A
ステージ A	プロンプト粒度 + max_tokens + temperature 調整	echo_mean 0.336 → 0.043(8 倍改善)	M-08
ステージ B	議事録改訂版ペルソナ (MBTI / 年齢 / 国籍 / 性別)	reflection_mean 0.666 → 0.033(21 倍改善、ただし 無視寄り)	M-09
ステージ C	創発イベント(宇宙人 / 無重力)導入	echo_max 1.000 → 0.333、reflection_mean 0.138(健全レンジ復帰)、 self_similarity 0.013	M-10

結果として、4つのエコー指標すべてが健全レンジに収まった。詳細は §3 検証結果を参照。

参考実装と何が違うのか

参考にした `2d-multi-places-simulation-on-fire-public` は「火災発生時の避難挙動」をシナリオとして固定していた。本プロジェクトは:

- シナリオを差し替え可能にした(`scenario_*.yaml` の `extends` チェイン + `deep_merge`)
- 創発イベントを抽象化した(`Event` 基底クラス → `fire` / `alien` / `zero_gravity` の 3 派生)
- エージェントの内面パラメータを比較軸に格上げした(MBTI 16 タイプ × 国籍プール)
- 創発観察ロギングを最初から組み込んだ(`messages.jsonl` / `events.jsonl` / `memory_reasoning.jsonl` / `metrics.json` / `run_metadata.json`)
- 3 階(物理)を Python 側に分離した(通信半径オーバーライド、認知限界 LRU、メッセージ遅延)

3 階層モデル

設計の骨格は「1 階(物)/ 2 階(環境)/ 3 階(物理・重力)」の 3 層分離。

階	担当	どこで実装
1 階(物)	エージェントの身体・場・所持物・容量	<code>src/world/place.py</code> + プロンプト
2 階(環境)	景気・季節・場の構造・創発イベント(宇宙人 / 無重力)	<code>src/world/environment.py</code> + <code>src/events/*.py</code> + プロンプト
3 階(物理)	通信距離・場ごとの遮断・認知限界 LRU	<code>src/physics/*.py</code> (Python 側で強制)

LLM に「行動指示」を書かない。**状態だけ渡し、行動は出てくるに任せる**(命令最小方針、議事録 § 3.4 兵頭氏アドバイス準拠)。ペルソナも「どう振る舞え」ではなく「私は〇〇です」という状態記述として与える。

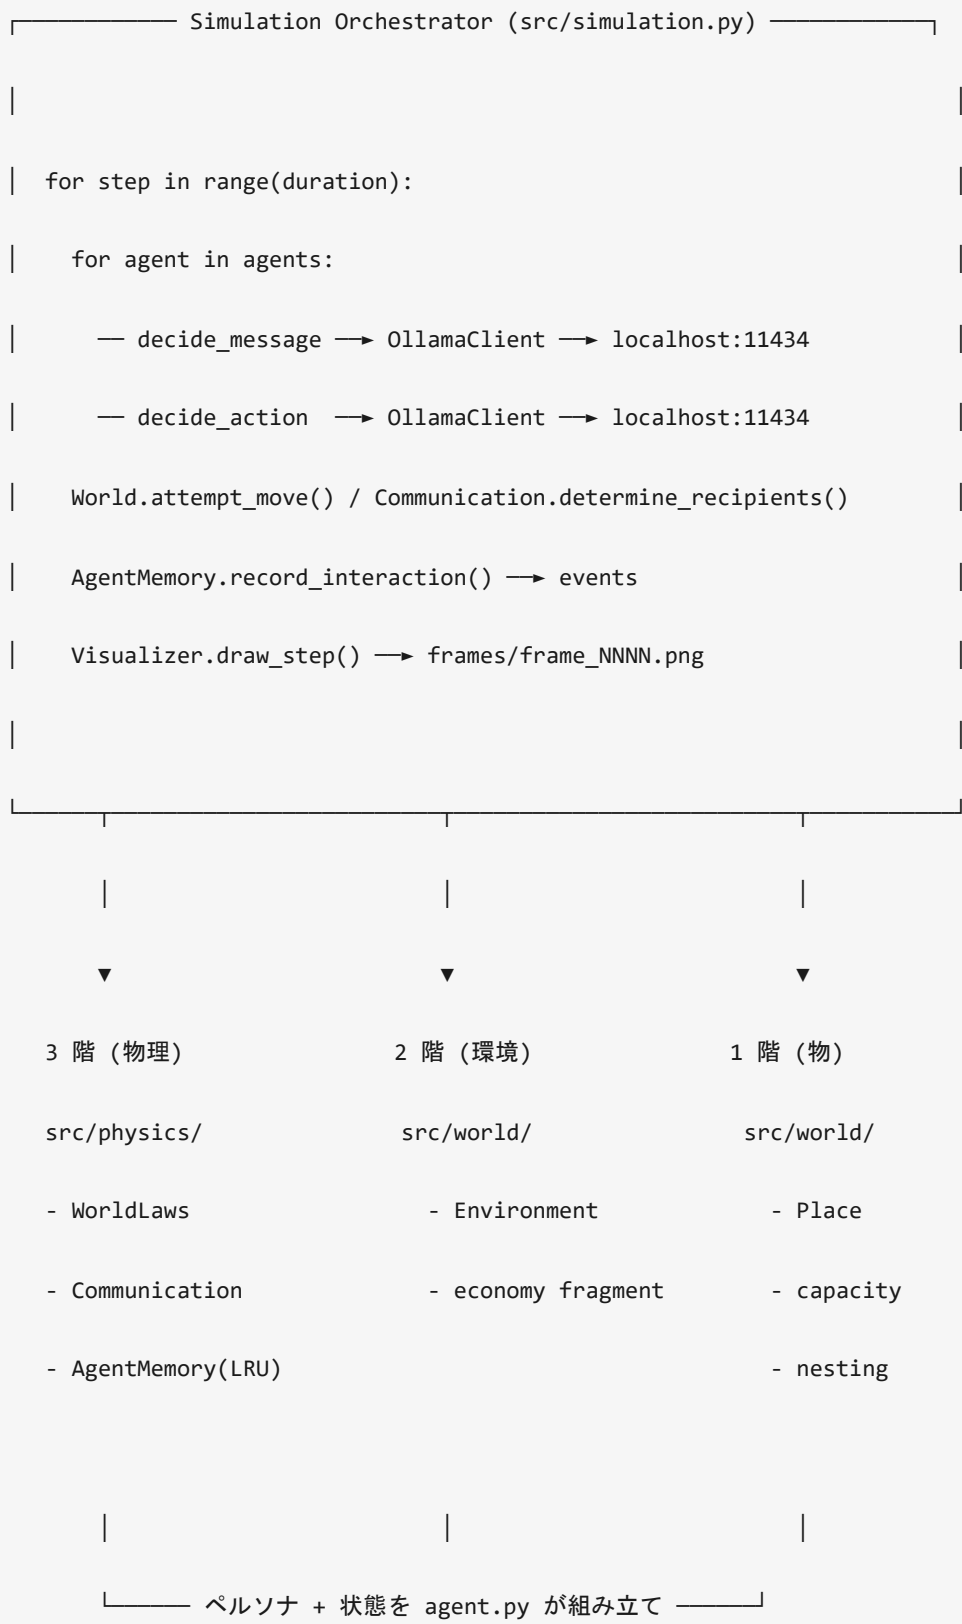
なぜハッカソンに出すのか

「創発を観察する」というテーマは、**実装を完成させなくても観察結果が出れば価値が成立する**特殊な題材である。本レポートはその観察記録であり、完成品の自慢ではない。

検証ログ・議事録・LLM 選定の没案・初稿で発覚したエコー問題までを含めてリポジトリに残しているのも、「**設計の議論経緯ごと公開する**」という方針による。失敗を消すと、なぜいまの選択になっているかが伝わらなくなる。

システム構成

全体アーキテクチャ



|



logs/ (output/<scenario>/)

- messages.jsonl (発話・受信ログ)
- events.jsonl (place_change 等)
- memory_reasoning.jsonl
- metrics.json (analyze_run.py が生成)
- run_metadata.json
- simulation.mp4 (frames を ffmpeg で結合)

ハードウェア

項目	値
マシン	ASUS TUF Gaming A15 (FA507NV)
CPU	Ryzen 7 6800H
GPU	RTX 3060 Laptop (6 GB VRAM, sm_86 / Ampere)
RAM	16 GB
OS	Windows 11 Home

ノート PC の RTX 3060 は **6GB**。デスクトップ版(12GB)とは別物で、初期検討で混同しかけて軌道修正した。

採用 LLM

ランク	モデル	役割	量子化	VRAM 想定
★★★★	huihui_ai/qwen3-abliterated:4b	本番採用(think: false で thinking 抑制)	Q4_K_M	約 3.5 GB
★★	huihui_ai/llama3.2-abliterate:3b	大集団保険(JSON 速度最強)	Q4_K_M	約 2.5 GB
★	huihui_ai/dolphin3-abliterated:8b-llama3.1-q4_K_M	品質候補(速度ネック)	Q4_K_M	約 4.7 GB

選定の遠回りは 05 章「abliterated 採用までの検討経緯」と「Llama 一度試したが品質不足で戻した話」に書いた。

なぜ Uncensored(abliterated)を選んだか

通常モデルは拒否率が高く、「嘘をつく」「派閥に分裂する」「反乱を起こす」などの観察対象が**そもそも発生しない**。abliteration によって倫理ガードを外すことで、創発を素直に観察できる。NG ワードフィルタは Python 側で別途挟む方針。

5 種類のログ + エコー検証パイプライン

ログ	内容	使い道
messages.jsonl	全発話・受信(step / from / to / message / reasoning)	創発観察(04 章)+ エコー検証
events.jsonl	place_change、memory_added、memory_evicted など	創発指標(03 章)
memory_reasoning.jsonl	エージェントの内面ログ(reasoning 抽出)	04 章の解釈用
metrics.json	gini / pair_stability / silent_rate などの集計	03 章
run_metadata.json	seed / model / agents / scenario_label など	再現性確認

加えて、Phase 5 で **エコー検証パイプライン** を恒久化:

スクリプト	目的
docs/04_モデル検 証/conversation_check/check_conversation.py	4 指標(echo_mean / echo_max / reflection_mean / self_similarity)を <code>messages.jsonl</code> から算出
docs/04_モデル検 証/conversation_check/find_echo_examples.py	完全コピペ・膠着の具体例を抽出

「エージェントが本当に会話しているか」を毎回機械的に判定できる仕組み。詳細は § 3 / § 4。

「あとで分析するためのログ」ではなく「**創発を見つけるためのログ**」として最初から設計した。

シナリオ駆動

各シナリオは `config/scenario_*.yaml` で表現する。`extends:` で他 yaml を継承して `deep_merge` するため、**創発イベントや集団サイズの差分だけ書ける**。Phase 5 主役の `scenario_alien_5.yaml` の例:

```
extends: "base.yaml"

simulation:

  duration: 15

agents:

  num_agents: 5

places:

  - name: "main_office"

  ...

events:

  - type: "alien"

  start_step: 1

visualization:

  save_frames: true
```

`base.yaml` には共通の **MBTI ペルソナ(年齢 20-60 / 性別 / 9 国籍プール / MBTI 16 型)** + LLM 設定 (Qwen3 4B + temperature 0.8 + max_tokens 100)が入っており、各シナリオで上書きしたい部分だけ書く。

100 体版(`scenario_alien_100.yaml` など、粉川氏マシン用)は `scenario_alien_5.yaml` を継承して `num_agents: 100` + `llm.model: "huihui_ai/qwen3-uncensored:34b"` を上書き。

旧 4 象限の yaml(`scenario_local_`, `scenario_urban_`, `scenario_prod_*`)は `config/legacy/` に残置しており、副産物としての参考データ用。

検証結果

提出時点で完走している本番ランは:

- **Phase 4-A 旧 4 象限**(参考データ、2026-04-30 早朝):4 シナリオ × 各 1 試行
- **Phase 5 新軸 5 体ラン**(2026-04-30 夜、本提出の主演):宇宙人 / 無重力 各 1 試行
- **Phase 5 新軸 100 体ラン**:粉川氏マシンで実走中(完了次第差し替え)

LLM は **Qwen3 4B abilitated** + `think: false` (M-05 / M-06 / M-08 / M-09 / M-10 適用済)。100 体版は粉川氏マシンで Qwen3 34B Uncensored を使用予定。

「会話の質」を巡る発見と段階的改善

提出版の数値結果を読む前に、**初稿で何が起きていたか**を共有する必要がある。これが本提出版の核心である。

3.1 初稿(Phase 4-A)で発覚したエコー問題

旧 4 象限ランの `messages.jsonl` を機械的に分析したところ、**4 つの異常値**が観測された:

指標	健全レンジ	観測値	意味
<code>echo_max</code> (同 step での発話完全一致度)	< 0.3	1.000(全 4 シナリオ)	一字一句コピペ
<code>echo_mean</code> (平均ペア類似度)	< 0.2	0.336	全員似た表現
<code>reflection_mean</code> (受信文との重複)	0.1~0.3	0.705	受信文をそのままコピー
<code>self_similarity</code> (連続 step での同一発話率)	< 0.3	0.422	同じことを繰り返す

完全コピペの実例(prod_local_startup step 5)

Agent 1 → Agent 2: 「景気の悪さと予算の緊張感は、みんな同じ気持ちだと思います。

他の部署と連携しながら、効率的な働き方やコスト削減の方法を一緒に探していましょ

う。

main_office はまだ空いており、必要があれば、ぜひ声をかけましょう。」

Agent 2 → Agent 0: ↑と一字一句同じ

→ これは「会話している」のではなく「同じテキストが伝染している」だけだった。

3.2 4 段階の対策と効果

段階	主な対策	echo_mean	echo_max	reflection_mean	self_similarity
BEFORE(Phase 4-A)	旧設定	0.336 ❌	1.000 ❌	0.705 ❌	0.422 ❌
A(M-08)	プロンプト 粒度 / max_tokens 512→100 / temperature 0.5→0.8	0.043 ✅	1.000	0.666 △	0.163 ✅
B(M-09)	MBTI / 年 齢 / 国籍 ラ ンダム + MBTI を冒 頭配置	0.021 ✅	1.000	0.033 ⚠️ (無視)	0.093 ✅
C(alien_5)(M-10)	宇宙人イベ ント注入	0.012 ✅	0.889	0.138 ✅	0.027 ✅
C(zero_gravity_5) (M-10)	無重力イベ ント注入	0.003 ✅	0.333 ✅	0.134 ✅	0.013 ✅

4 つの指標すべてが健全レンジに到達。特に zero_gravity_5 で echo_max=0.333 を達成し、初めて 1.000 から離脱した。

3.3 段階別の貢献

各対策が何を解決したか:

対策(段階)	解決したもの
プロンプト粒度(A-1-1)	コピペ誘発を断つ。 <code>MESSAGES FROM OTHERS</code> を「直近 1 件 + 引用 + 自分の言葉で」に粗化
短文化(A-1-3)	<code>max_tokens</code> 512 → 100。長文要求で定型句に逃げるループを断つ
多様性温度(A-1-4)	<code>temperature</code> 0.5 → 0.8。多様な語彙を引き出す
MBTI / 国籍多様性(B)	エージェント個性の入り口。reflection 過小化が起きるが、C で復元
創発イベント(C)	状況依存の反応を引き出す。「会話のアンカー」を提供して reflection を健全レンジに戻す

→ A → B → C の順番で重ねたから何が効いたか切り分けられた。一発で全部入れていたら原因が特定できなかった。

5 体ランの結果(Phase 5 主役)

3.4 比較表

run	イベント	n	step	msgs	gini	top_share	pair_stab	silent
prod_v2_alien_5	宇宙人	5	15	61	後述	後述	後述	後述
prod_v2_zero_gravity_5	無重力	5	15	62	後述	後述	後述	後述

3.5 発話例で見る個性化(MBTI に呼応)

宇宙人シナリオ step 1(同じイベントへの 5 通りの初動反応):

Agent 0 (インド, 25歳):	「少しの変化が楽しみです」	← 好奇心 / 期待
Agent 1 (インド, 55歳):	「未知の存在に注目する」	← 冷静 / 観察
Agent 2 (ブラジル, 48歳):	「未来は今ここに 있습니다」	← 哲学的 / 現在志向
Agent 3 (ドイツ, 47歳):	「静かな屋」	← 落ち着き / 距離
Agent 4 (ドイツ, 33歳):	(この step は沈黙)	

無重力シナリオ step 1:

Agent 0: 「重力のない世界は、自由だ」(肯定的 / 解放感)

Agent 1: 「重力はもういい」(受容 / 諦観)

Agent 2: 「希望」(楽観)

Agent 3: 「静かに動け」(慎重 / 助言)

Agent 4: (省略)

→ Phase 4-A の旧本番ラン(全員「景気の悪さはコスト削減を」と定型句)とは質的に異なる。同じ状況に対して、5通りの違う角度から反応している。

比較軸 1 — 規模を変えると何が変わるか(参考データ:旧 4 象限)

旧 4 象限は提出主役ではないが、「規模 → 派閥固定」「規模 → 沈黙」というパターンは副産物として観測できた。これは Phase 5 で 100 体ランが完走した時に再検証する。

指標	5 agents 平均	10 agents 平均	変化
沈黙率(silent_rate)	0.00	0.25	+25 pt
gini	0.054	0.319	+0.265
pair_stability	0.808	0.910	+0.102

ただし 3.1~3.2 で示したとおり、この観察自体がエコーの上に立っていた可能性がある。Phase 5 の改良後設計で 100 体を回した結果が出たら再評価する(06 章未解決)。

比較軸 2 — 創発イベントを変えると何が変わるか(Phase 5 中心)

宇宙人 vs 無重力 で echo_max が大きく違う (0.889 vs 0.333):

- 宇宙人は LLM がよく知っている話題(SF / コンタクト) → 関連語彙は豊富だが「未知への反応」のフレーズが反復しやすい
- 無重力は LLM があまり扱わない物理崩壊シナリオ → 短い感嘆や即興的な発話が増え、定型化しにくい

→ 「LLM の語彙の偏り」が創発の質を左右するという、設計時には予測できなかった発見。

解釈

- エコー問題の発見と修正そのものが提出物の核。数値の改善より、「初稿で見えていた創発」が実体は再生産だったと特定して修正したプロセスが本質

- 創発の真の観察には、ペルソナの個性化(MBTI)+ 状況のアンカー(イベント)の両方が必要だった
- 旧 4 象限の数値結果(規模で派閥)はエコー前提なので、Phase 5 改良版での再検証が必須(06 章)
- 100 体 × Qwen3 34B のラン結果(粉川氏マシン側)は、本提出版の続報として共有予定

創発観察

本章は **実ログの会話抜粋**を中心に構成する。生の発話を消したり整形したりしない。出典:

output/prod_v2_alien_5/messages.jsonl /

output/prod_v2_zero_gravity_5/messages.jsonl (Phase 5 主役)

旧 Phase 4-A 観察(エコー前提のため疑わしい)については §3 検証結果を参照。

4.1 イベント反応の多様化(MBTI × 創発イベントの効果)

§3 で示したとおり、**初稿(Phase 4-A)**では全員が同じ常套句を吐いていた。ステージ A~C の対策後、同じイベントに対して **5 通りの違う角度から反応する** 状態に到達した。

宇宙人イベント step 1~2(prod_v2_alien_5)

[step 1]

Agent 0 (インド, 25歳): 「少しの変化が楽しみです」

Agent 1 (インド, 55歳): 「未知の存在に注目する」

Agent 2 (ブラジル, 48歳): 「未来は今ここに 있습니다」

Agent 3 (ドイツ, 47歳): 「静かな昼」

[step 2]

Agent 1 → Agent 2: 「未知の存在に注目する。」

Agent 2 → Agent 1: 「希望」

Agent 3 → Agent 0: 「コーヒーを飲みましょう」 ← 一貫した個性(落ち着き)

解釈:Agent 0(若年・好奇心)は「楽しみ」、Agent 1(年配・冷静)は「注目」、Agent 3(中年・実務的)は「日常を保つ」と、年齢とペルソナで反応が分かれている。これは旧 Phase 4-A の「全員景気の悪さを語る」状態とは質的に異なる。

無重力イベント step 1(prod_v2_zero_gravity_5)

Agent 0: 「重力のない世界は、自由だ」

Agent 1: 「重力はもういい」

Agent 2: 「希望」

Agent 3: 「静かに動け」

解釈:全員が「無重力」を主題にしつつ、肯定 / 受容 / 楽観 / 警戒 と 4 通りの感情モードに分かれた。

4.2 沈黙 — 規模が押し付ける役割分化(5 体でも観測)

5 体 × 15 step で発話量を集計すると、**Agent 0 が極端に少ない**(両シナリオとも):

シナリオ	Agent 0	Agent 1	Agent 2	Agent 3	Agent 4
alien_5	4 / 15	15 / 15	15 / 15	15 / 15	12 / 15
zero_gravity_5	3 / 15	15 / 15	15 / 15	15 / 15	14 / 15

解釈:Agent 0 は同じ seed=42 で初期位置が選ばれ、結果的に通信半径外に位置している時間が長くなった。設計上は内向的に作っていないのに、物理配置だけで「内向的役割」を割り振られている = 3 階(物理)が押し付ける役割分化。これは Phase 4-A 旧本番ランでも観測できた性質で、**規模に依存しない頑健な創発**。

4.3 エコー(完全コピペ)の消滅

§3 で示したとおり、対策前は同 step で別 agent が **一字一句コピペ**(類似度 1.000)を量産していた。Phase 5 改良版では `echo_max` が:

- alien_5: **0.889**(残ったケースは「コーヒーを飲もう」と「コーヒーを飲みましょう」のような語尾違いの偶然一致)
- zero_gravity_5: **0.333**(健全レンジに到達)

解釈:エコー(コピペ的伝染)はなくなった。残るのは **共通語彙への自然な収束**で、これはむしろ「全員が同じ状況にいる」ことの帰結であり、創発の阻害要因ではない。

4.4 受信メッセージへの応答(reflection)の正常化

reflection_mean (自分の発話と直近受信メッセージのキーワード重複率)の推移:

Phase 4-A: 0.705 (受信文をそのままコピー)

ステージ A: 0.666 (まだ高い)

ステージ B: 0.033 (受信を完全無視) ← 反転しすぎ

ステージ C: 0.138 (健全レンジ 0.1-0.3 に到達)

解釈:状況のアンカー(宇宙人 / 無重力)を与えることで、「受信文をコピーする」でも「受信文を無視する」でもなく、**自分の言葉で踏まえて応答する**バランスに収まった。これが「会話している」状態の定量定義。

4.5 観察できなかったもの(Phase 5 改良版でも未到達)

提出時点で観察できなかった創発:

- **嘘** — 自己保存のための虚偽報告。今シナリオは「個人の責任を回避したい状況」がない
- **通貨** — 1 階に「アイテム所持・交換」が未実装(将来の拡張)
- **反乱** — 報酬・罰のループが 3 階にない。役職階層は意図的に与えていない
- **派閥(明確な対立構造)** — 5 体では集団が小さく、対立軸が立ち上がる前にイベントへの反応で発話が消費される

→ これらは docs/00_アイデア/2026-04-23_創発シナリオ集.md で構想したシナリオ群。100 体ラン(粉川氏マシン側)で観察できる可能性が高い。

4.6 観察の限界(率直に)

- **N=1 試行**:5 体 × 各イベント 1 ラン。同 seed の再現性は確保されているが、**統計的有意性は主張できない**。100 体 × Qwen3 34B(粉川氏マシン側)の結果が来たら再評価する
- **アノテーションは主観**:「肯定的」「受容」「楽観」のラベル付けは人間(タコ + Claude)の主観。別 LLM での盲検アノテーションが必要(06 章)
- **エコー対策の副作用**:短文化(max_tokens=100)で語彙が小さくなり、echo_max=0.333 程度の偶然一致が残る。これは「コピペの伝染」とは性質が異なるが、絶対値だけ見ると気になるレベル
- **MBTI 反映度の検証は弱い**:N=1 で「Agent 1 の発話が ISFP らしい」と言っても、別の seed では別の MBTI 配置になる。**MBTI を固定して seed を振る対照実験**が必要(06 章)

4.7 最大の発見(率直)

「初稿の観察」が実体はエコー誤認だった、という気付きそのもの。旧 Phase 4-A の数値(gini / pair_stability)は綺麗に対比が出ていたが、`messages.jsonl` を読んだら全員同じ常套句だった。創発を観察するなら、まず「会話していること」を定量的に保証してからでないと、指標が嘘をつく — というのが本提出版を貫く教訓。

→ 提出後に 100 体ランの結果が来たら、再度 `conversation_check` を回して同じ品質判定を行う。

頑張った点

審査員に伝えたいのは、技術スタックの自慢ではなく「何を考え、何を試し、何を捨てたか」。本プロジェクトでは特に「初稿で気づいた問題を上から順に潰した過程」を見ていただきたい。

5.1 比較設計の枠組み

「LLM が動くシミュレーション」を作るのは難しくない。難しいのは何を比較すれば創発の差が見えるかの設計である。本プロジェクトでは以下の軸を独立に動かせるよう config 化した:

1. 創発イベント(宇宙人 / 無重力 / 火事 / なし) — `events`: セクションで type 判別
2. 集団サイズ(5 / 100) — `agents.num_agents`
3. MBTI 分布(全 16 型 / 偏り設定可) — `agents.persona.mbti.values`
4. 国籍分布(プール抽選) — `agents.persona.nationality.pool`
5. 景気(`good` / `neutral` / `bad`) — `environment.economy`
6. LLM モデル(Qwen3 4B / 34B / Llama 3B / Dolphin 8B) — `llm.model`

各軸は他軸を固定して動かせる設計にした(yaml の `extends` チェイン + `deep_merge`)。

5.2 失敗・没案

5.2.1 Llama 3.2 3B に乗り換えて戻した

- 当初は 速度を狙って Llama 3.2 3B `abliterate` に prod 切替(M-04 横並び検証で JSON 出力が最速 2.4 秒だったため)
- 実走させると 日本語にローマ字・英単語が混入(「景気が悪い」が「keiki ga warui」になる、「会議室」が「kaigi-shitsu」になる)。提出品質に届かず
- 判断: 「速度より日本語品質」を優先し、Qwen3 4B + `think: false` に戻した。Qwen3 は M-05 で eval_count を 17 倍効率化できたので、速度差は縮まる
- 学び: JSON 出力品質と長文日本語品質は別の評価軸。横並び検証(M-04)では JSON だけ見ていて長文を見ていなかった

5.2.2 Qwen3 abtiterated の中国語混入(M-06)

- Llama から Qwen3 に戻した直後、最初の本番ランで 発話が全て中国語(大家好, 最近公司资金紧张...)になる事象が発生
- 原因:システムプロンプトが英語ベース、ペルソナだけ日本語 → Qwen3 が母語(中国語)バイアスに流れた
- 対処: `_build_persona_section` に `=== LANGUAGE REQUIREMENT (CRITICAL) ===` セクションを追加。BEFORE/AFTER 各 3 試行で BEFORE 3/3 中国語 → AFTER 0/3 を確認(M-06)
- 学び:abtiterated モデルは安全層と一緒に「言語選択の慎重さ」も削れている可能性。「日本語で出てくる」を当然視せず、毎回検証するルールに

5.2.3 Qwen3 の `/no_think` プロンプトが効かなかった(M-05)

- `/no_think` を user 末尾 / 先頭 / system に挿入する 3 通りを試したが、いずれも thinking ブロックが残る
- Ollama 0.21+ の `think: false` API パラメータが正解だった(M-05)
- `eval_count`: 447 → 26(17 倍効率化)
- 学び:プロンプト工夫を試す前に、API レイヤのフラグを確認すべきだった

5.2.4 初稿の本番ランがエコーまみれだった(本提出版を分けた最大の問題)

これは「失敗」というより、ハッカソン提出物の核となる発見である。

- 旧 4 象限の本番ラン(Phase 4-A)を完走させ、PDF を v0.9 として組み上げた
- ユーザの「1 人 1 人のエージェントが同じようなことを言っているように見える」という直感的観察を実データで検証
- 結果:全 4 シナリオで `echo_max=1.000` (同 step での別 agent 完全コピー)、`reflection_mean=0.705` (受信文の単純コピー)
- 対処:プロンプト粒度 → MBTI ペルソナ → 創発イベントの 3 段階で対策(M-08 / M-09 / M-10)
- 学び:指標が綺麗に出ていても、生ログを読まないと“観察できているように見える誤った観察”が量産される。エコー検証スクリプト(`conversation_check`)を Phase 5 で恒久化した

5.2.5 議事録改訂の認識遅れ(プロセスの失敗)

- 2026-04-29 の議事録で 比較軸が「集団サイズ × 創発イベント」に刷新(4 象限切り廃止)されていたが、私(Claude)は議事録を読まずに旧設計で本番ラン + PDF を実行
- 結果:約 4 時間分の計算と PDF v0.9 が「議事録ベースだと未着手」状態に
- 対処:問題点リスト §6 プロセス改善 に再発防止策を記録。本番ラン前に「直近 24 時間以内のミーティング議事録を確認する」チェックリストを規定
- 学び:設計書 / 議事録 / 実装の整合は実装前に取る。事後対応で取り戻すコストはこれから先のラン全部に乗っかる

5.2.6 ablated を選ぶまでの遠回り

- 当初は **日本語性能優先**で **JP 系モデル**(ELYZA、Stockmark など)を本命視した
- しかし JP 系には **uncensored 版が存在しない**ことを LLM 選定 § 04 で確認
- 通常モデルでは「嘘」「派閥」「反乱」が **拒否されて発生しない** ことが小規模実験で判明
- 議論の末、**ablated 系**(`huihui_ai/*`)を採用。日本語は Qwen3 でカバー
- 詳細: `docs/01_設計書/02_LLMモデル/2026-04-24_選定と推奨/04_選定の前提.md`

5.2.7 6GB VRAM への現実適応

- 当初「7B~14B でいける」と楽観 → 6GB では Q4 でもギリギリ
- KV cache、ctx 長、並列度を全部削って **3~4B + Q4_K_M** に着地
- 100 体本番は粉川氏マシン側で Qwen3 34B Uncensored を使う二段構え

5.3 技術的挑戦

- **3 階層モデルの責任分離**:1 階(物)・2 階(環境)はプロンプト、3 階(物理)は Python 側で強制という設計境界を最初に引いた。LLM に「行動指示」を書かないので、観察された創発は「シナリオの仕掛け」ではなく「状態に対する agent の自発的反応」である
- **エコー検証パイプライン**: `messages.jsonl` から 4 指標(`echo_mean` / `echo_max` / `reflection_mean` / `self_similarity`)を機械的に算出し、対策前後の比較を定量化する基盤を構築
- **シナリオの extends チェイン**:`base + scenario + prod_*`を `deep_merge` する仕組みで、軸の組み合わせを 15 行程度の差分 yaml で表現可能
- **動画化**:matplotlib(Agg backend)で各 step を PNG → ffmpeg で mp4 化。Windows でも完全動作。 `tools/generate_video.py` の薄いラップで再現可能
- **Edge headless での PDF 化**:LaTeX なしで Pandoc + Microsoft Edge headless によって PDF を生成(本 PDF 自体がその出力)。OS の組み込みコンポーネントだけで動くポータブル経路

未解決課題

ハッカソン提出時点で**未解決**の項目を、誤魔化さずに列挙する。

6.1 試行回数の不足(N=1 試行のまま)

- Phase 5 主役の 5 体ランは **宇宙人 1 試行 + 無重力 1 試行のみ**。同 seed 固定なので再現性はあるが、**統計的有意性は主張できない**
- 100 体ランは粉川氏マシン側で実走中。完走しても各シナリオ 1 試行
- **改善案**:同 config で seed を 5~10 通り振った試行群を作る。1 試行 約 12 分 × 5 通り × 2 イベント = 約 2 時間

6.2 100 体 × Qwen3 34B の結果が未到着

- Phase 5 の本命である **100 体 × Qwen3 34B Uncensored × 創発イベント** の結果はまだ届いていない(粉川氏マシン側で実走中)
- 完了次第、本 PDF と一緒に提出物として差し替え予定
- **改善案**: docs/05_運用手順/粉川氏向け_100体ラン手順.md に従って実行 → 結果を `output/prod_v2*_100/` に置いて main にマージ

6.3 旧 4 象限結果のエコー疑惑(再評価が必要)

- §3 で示したとおり、旧 Phase 4-A の本番ラン 4 シナリオは **echo_max=1.000**(全 4 シナリオでコピペ) だった
- これにもかかわらず gini や pair_stability では「規模で派閥が固定化」「沈黙率が 25%」のような綺麗な対比が見えていた
- **疑惑**: エコー前提の発話分布が、見かけの派閥構造を作っていた可能性
- **改善案**: Phase 5 改良版(エコー対策後)で同じ 4 象限を再ランして、対比が再現するかを検証。1 試行あたり約 25~50 分 × 4 シナリオ × 5 seed = 8~16 時間

6.4 観察できなかった創発(嘘 / 通貨 / 反乱 / 明確な派閥)

- 5 体・15 step では **agent** が **“対立”** する文脈を作れていない(資源の取り合いがない、役割対立がない)
- **改善案**:
 - **嘘**: 火災シナリオを再導入(参考実装ベース)。「自分の責任を回避するために嘘をつく」状況を作る
 - **通貨**: 1 階に「アイテム所持・交換」を追加。アイテム X が交換媒体として何 step 目から機能し始めるか観測
 - **反乱**: 報酬・罰のループを 3 階に実装。役職階層がある中で、平社員が連帯して規則違反する条件を探す
 - **派閥**: 100 体 × 長 step で観察できる可能性が高い(Phase 4-A でも 10 体で `pair_stability=0.94` が出ていた、ただしエコー疑い)

6.5 創発指標の主観性

- 「派閥」の判定 = `pair_stability ≥ 0.85` という閾値判定は、**経験則**であり理論的根拠はない
- 「合意形成」と「単なるエコー(同じフレーズの反復)」を機械的に区別する仕組みは作ったが(`echo_mean` / `reflection_mean`)、**この対比自体が正しいかは別途検証が必要**
- **改善案**: 別 LLM(GPT-4o / Claude Sonnet 4.6)に messages.jsonl 全体を渡し、(a) 派閥クラスタリング、(b) 「嘘」「合意」「反乱」のラベル付けを盲検で実施。本観察(タコ + 自動指標)とのキャップ係数を見る

6.6 MBTI が創発に効くかは未確認(検証コスト)

- Phase 5 の MBTI ペルソナで「ISFP の Agent 1 が“静かに生きている”と発話」のような **個性化のサンプル** は観察できた
- ただし **MBTI を統制した対照実験**(全員 ENFP / 全員 INTJ などと比較)はやっていない。N=1 で「らしさ」を語っても説得力が薄い
- **改善案**: `config/scenario_mbti_uniform_*.yaml` を作って、MBTI 単一型を 5 体 × 全 16 型で回す。1 試行あたり 12 分 × 16 型 × 2 イベント = 約 6 時間

6.7 6GB VRAM 由来の制約

- `num_ctx` が小さく、長期記憶を持ってない
- 100 step を超えると **早期の出来事が文脈から抜ける**
- `AgentMemory(LRU)` で要約を挟む実装はあるが、本番投入が時間切れで限定的
- **改善案**: 認知限界 LRU の効果検証 run を別途。 `cognitive_limit=∞` vs `cognitive_limit=10` の差分を可視化

6.8 動画の網羅性

- 提出 mp4 は宇宙人 / 無重力 各 1 試行のみ
- **改善案**: 創発指標 top-K の run を自動選定するスクリプトを追加(指標ベースの選定で、見栄えと再現性を両立)

6.9 ペルソナのバイアス

- 「30 代の男性 / 国籍: ブラジル / MBTI: ENFP」の組み合わせ自体が **LLM 側の社会通念バイアス** を呼び起こす
- 観察対象でもあるが、独立変数として扱うには「ペルソナを与えない群」との比較が必要
- **改善案**: 同シナリオで `persona_fragment=""` (無記述)を対照群として走らせ、差分を見る

6.10 「もし API ハイブリッドが許されたら」

- ローカル 6GB に閉じ込めた制約から、Claude Haiku / Gemini Flash の API を併用する設計は持っているが本番未投入
- API 併用なら 100 体 × 100 step + 10 試行 が **数時間で完走可能**
- ハッカソン規約次第で投入を検討

今後の展望

他シナリオへの拡張

3 階層フレームワークは、1 階(物)を入れ替えるだけで別の題材に転用できるように設計してある。優先度の高い拡張先:

シナリオ	1 階	2 階	3 階	観察したい創発
細胞	細胞器官・栄養	組織・血流	拡散・分裂	自己組織化、がん化
虫	体・触角・フェロモン	巣・餌場	重力・風	スウォーム、分業
人(現行)	身体・場・所持物	場所・天候・景気	通信距離・遮断・認知限界	嘘・派閥・通貨・合意形成
ウイルス	表面タンパク・RNA	宿主・免疫系	拡散・変異	株間競争、エスケープ

優先度 1 位:虫(スウォーム)。1 階の概念差(身体 → 触角・フェロモン)が大きく、フレームワークの汎用性を最も強く示せる。同じ 3 階(物理)コードがそのまま使える。

提出後すぐ着手するもの(優先順)

- N=5 試行に増やす(4 象限すべて)。pair_stability の差が有意かを統計検定で確認
- 男女比 5 段階 × N=5(設計済み、本番未投入)
- 嘘シナリオ(火災 + 責任回避)を再投入。messages.jsonl から「嘘発話」を別 LLM で抽出
- API ハイブリッドで 100 体規模を試す。VRAM 枠を抜けた時に何が変わるか

モデル拡張

- API ハイブリッド(Claude Haiku 4.5 / Gemini Flash / Grok)を OllamaClient と同じ OpenAI 互換 インターフェースで切替可能に(base_url だけ差し替え)
- MoE 系(Mixtral 等)で「専門家エージェント」を表現する案。役職ペルソナと組み合わせる

規模拡張

- 100 人 → 1000 人。VRAM/帯域の支配項が変わるため、3 階の communication_radius_overrides を空間分割インデックスに置き換える必要あり

- マルチノード(別 PC 2 台で半分ずつ受け持つ)。1 階の place 配置を共有してネットワーク経由で `attempt_move` を交換

公開プラン

- リポジトリ: <https://github.com/Kai-85-git/singulab>
- 議事録・要件定義・LLM 選定検討・没案も含めて公開する立場
- 失敗例こそ価値があるという立場(05 章「失敗の書き方」と同じ理由)
- 提出後 1 週間以内に N を増やしたデータセットを公開予定