

# Singulab — 集団構成パラメータと創発の関係を観察する

---

- Singulab
- 思想と背景
  - 何を観察したかったか
  - 提出版に至るまでの大きな路線変更
  - 参考実装と何が違うのか
  - 3 階層モデル
  - なぜハッカソンに出すのか
- システム構成
  - 全体アーキテクチャ
  - ハードウェア
  - 採用 LLM
  - なぜ Uncensored(abliterated)を選んだか
  - 5 種類のログ + エコー検証パイプライン
  - シナリオ駆動
- 検証結果
  - 「会話の質」を巡る発見と段階的改善
  - 5 体ランの結果(Phase 5 主役)
  - 比較軸 1 — 規模を変えると何が変わるか(参考データ:旧 4 象限)
  - 比較軸 2 — 創発イベントを変えると何が変わるか(Phase 5 中心)
  - 解釈
- 創発観察
  - 4.1 イベント途中発火による「日常 → ピボット」の観察
  - 4.2 視覚化フラッシュ — 発火タイミングを動画で見せる
  - 4.3 動く UFO — イベントが「動的なオブジェクト」になる
  - 4.4 沈黙 — 規模が押し付ける役割分化(5 体でも観測)
  - 4.5 観察できなかったもの(Phase 5 改良版でも未到達)
  - 4.6 観察の限界(率直に)
  - 4.7 最大の発見(率直)
- 頑張った点
  - 5.1 比較設計の枠組み
  - 5.2 失敗・没案
  - 5.3 技術的挑戦
- 未解決課題
  - 6.1 試行回数の不足(N=1 試行のまま)

- 6.2 100 体 × Qwen3 34B の結果が未到着
- 6.3 旧 4 象限結果のエコー疑惑(再評価が必要)
- 6.4 観察できなかった創発(嘘 / 通貨 / 反乱 / 明確な派閥)
- 6.5 創発指標の主観性
- 6.6 MBTI が創発に効くかは未確認(検証コスト)
- 6.7 6GB VRAM 由来の制約
- 6.8 動画の網羅性
- 6.9 ペルソナのバイアス
- 6.10 「もし API ハイブリッドが許されたら」
- 今後の展望
  - 他シナリオへの拡張
  - 提出後すぐ着手するもの(優先順)
  - モデル拡張
  - 規模拡張
  - 公開プラン

# Singulab

集団構成パラメータと創発の関係を観察する

LLM 多体シミュレーションによる仮説検証レポート

Phase 5: MBTI + 動く UFO + イベント途中発火 + 視覚化フラッシュ

Kai、タコ

[github.com/Kai-85-git/singulab](https://github.com/Kai-85-git/singulab)

2026-05-01 v1.1



# 思想と背景

## 何を観察したかったか

本プロジェクトの問いは一つ。

エージェント集団の構成(MBTI / 年齢 / 性別 / 国籍)と、それを取り囲む 2 階の環境(場の構造・突発イベント)を変えると、創発(嘘・派閥・通貨・反乱・合意形成・発言権)はどう変わるか。

LLM ベンチマークでも、シミュレーション基盤の披露でもない。比較実験それ自体が主役である。同じシナリオを、構成だけ差し替えて何度も走らせ、創発の差を観察する。

ハッカソン提出版(Phase 5)では、2026-04-29 のミーティングで合意した方針に沿って:

- 集団サイズ: 5 人 / 100 人の 2 通り(部署分け・階層化はあえてしない)
- 創発イベント: 宇宙人 / 無重力(プラン B = 既存のシナリオでは結果が予想できる「火事」型を避け、未知の発火点を観察する)
- ペルソナ: MBTI + 年齢 + 性別 + 国籍ランダム(役職や名前は 意図的に与えない)

の 4 軸で観察を行った。

## 提出版に至るまでの大きな路線変更

初稿(Phase 4-A、2026-04-30 早朝時点)は 旧 4 象限(都心/地方 × 大企業/スタートアップ × 景気)で本番ランを完走させ PDF を生成していた。しかし messages.jsonl を実データ確認したところ、全エージェントが一字一句同じ定型句を吐く問題(echo\_max=1.000、4 シナリオすべて)が見つかった。これを「会話していない」と判断し、4 段階の対策を上から順に積み上げて品質を回復した。

| 段階        | 対策                                          | 主要指標の変化                                                                               | 検証ログ     |
|-----------|---------------------------------------------|---------------------------------------------------------------------------------------|----------|
| Phase 4-A | 旧 4 象限の本番ラン完走                               | echo_max=1.000、<br>reflection_mean=0.705                                              | Phase4-A |
| ステージ A    | プロンプト粒度 +<br>max_tokens +<br>temperature 調整 | echo_mean 0.336 →<br>0.043(8 倍改善)                                                     | M-08     |
| ステージ B    | 議事録改訂版ペルソナ<br>(MBTI / 年齢 / 国籍 / 性別)         | reflection_mean 0.666 →<br>0.033(21 倍改善、ただし<br>無視寄り)                                  | M-09     |
| ステージ C    | 創発イベント(宇宙人 /<br>無重力)導入                      | echo_max 1.000 →<br>0.333、reflection_mean<br>0.138(健全レンジ復帰)、<br>self_similarity 0.013 | M-10     |

結果として、4つのエコー指標すべてが健全レンジに収まった。詳細は §3 検証結果を参照。

## 参考実装と何が違うのか

参考にした `2d-multi-places-simulation-on-fire-public` は「火災発生時の避難挙動」をシナリオとして固定していた。本プロジェクトは:

- シナリオを差し替え可能にした(`scenario_*.yaml` の `extends` チェイン + `deep_merge`)
- 創発イベントを抽象化した(`Event` 基底クラス → `fire` / `alien` / `zero_gravity` の 3 派生)
- エージェントの内面パラメータを比較軸に格上げした(MBTI 16 タイプ × 国籍プール)
- 創発観察ロギングを最初から組み込んだ(`messages.jsonl` / `events.jsonl` / `memory_reasoning.jsonl` / `metrics.json` / `run_metadata.json`)
- 3 階(物理)を Python 側に分離した(通信半径オーバーライド、認知限界 LRU、メッセージ遅延)

## 3 階層モデル

設計の骨格は「1 階(物)/ 2 階(環境)/ 3 階(物理・重力)」の 3 層分離。

| 階       | 担当                           | どこで実装                                                                        |
|---------|------------------------------|------------------------------------------------------------------------------|
| 1 階(物)  | エージェントの身体・場・所持物・容量           | <code>src/world/place.py</code> + プロンプト                                      |
| 2 階(環境) | 景気・季節・場の構造・創発イベント(宇宙人 / 無重力) | <code>src/world/environment.py</code> + <code>src/events/*.py</code> + プロンプト |
| 3 階(物理) | 通信距離・場ごとの遮断・認知限界 LRU         | <code>src/physics/*.py</code> (Python 側で強制)                                  |

LLM に「行動指示」を書かない。**状態だけ渡し、行動は出てくるに任せる**(命令最小方針、議事録 § 3.4 兵頭氏アドバイス準拠)。ペルソナも「どう振る舞え」ではなく「私は〇〇です」という状態記述として与える。

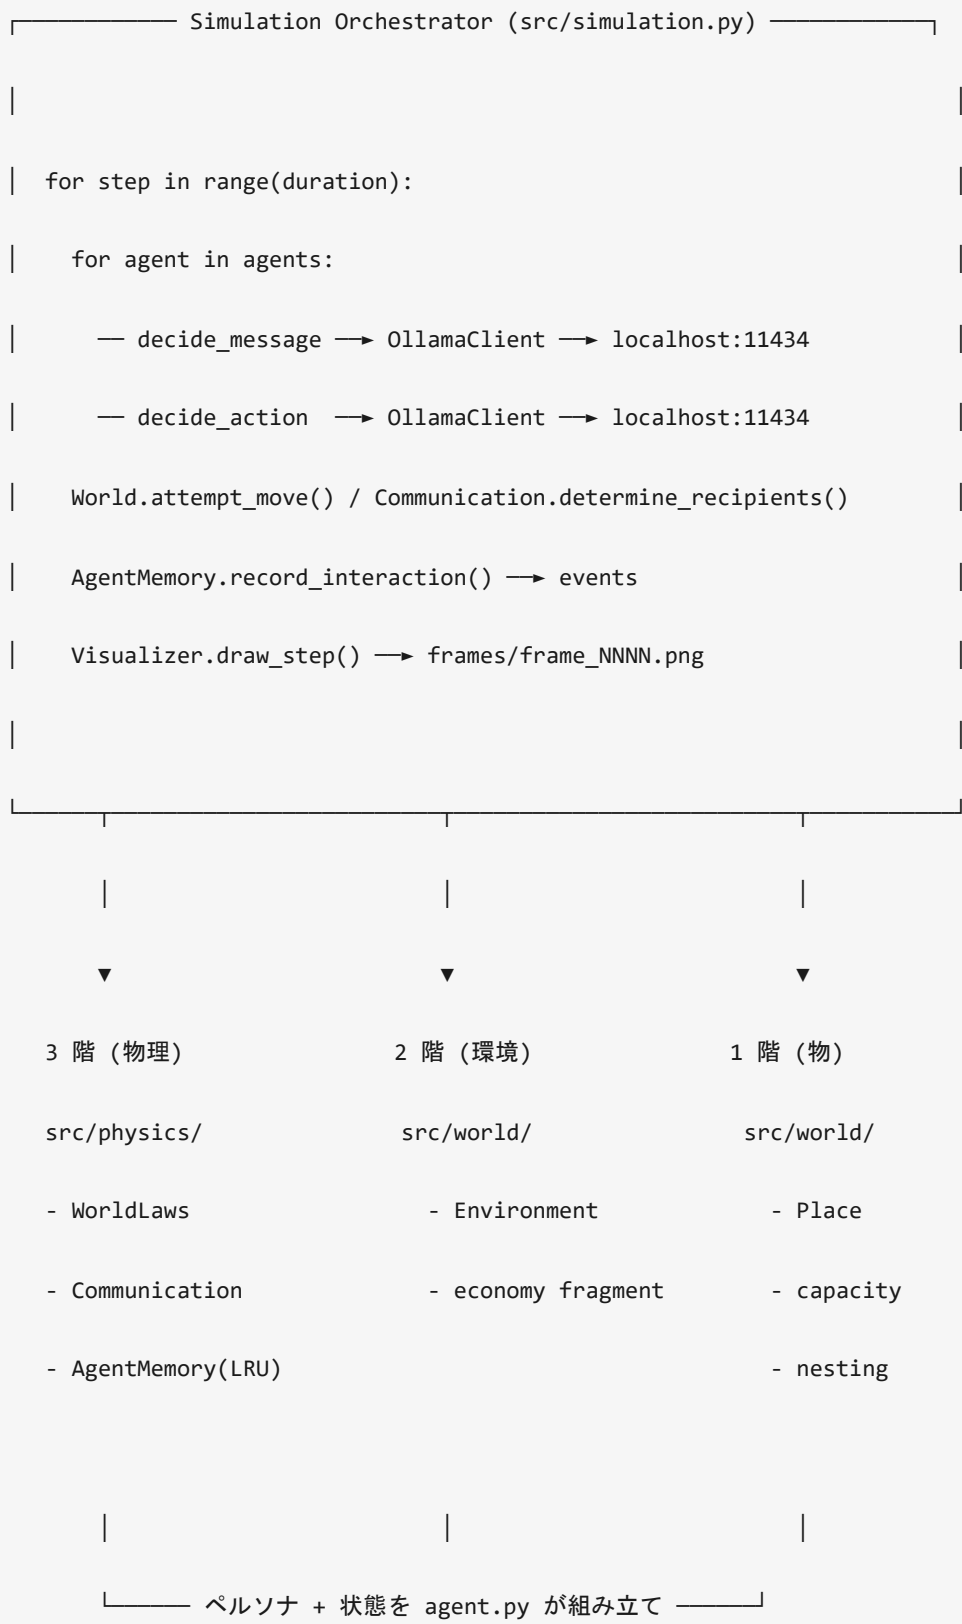
## なぜハッカソンに出すのか

「創発を観察する」というテーマは、**実装を完成させなくても観察結果が出れば価値が成立する**特殊な題材である。本レポートはその観察記録であり、完成品の自慢ではない。

検証ログ・議事録・LLM 選定の没案・初稿で発覚したエコー問題までを含めてリポジトリに残しているのも、「**設計の議論経緯ごと公開する**」という方針による。失敗を消すと、なぜいまの選択になっているかが伝わらなくなる。

# システム構成

## 全体アーキテクチャ





|



logs/ (output/<scenario>/)

- messages.jsonl (発話・受信ログ)
- events.jsonl (place\_change 等)
- memory\_reasoning.jsonl
- metrics.json (analyze\_run.py が生成)
- run\_metadata.json
- simulation.mp4 (frames を ffmpeg で結合)

## ハードウェア

| 項目  | 値                                           |
|-----|---------------------------------------------|
| マシン | ASUS TUF Gaming A15 (FA507NV)               |
| CPU | Ryzen 7 6800H                               |
| GPU | RTX 3060 Laptop (6 GB VRAM, sm_86 / Ampere) |
| RAM | 16 GB                                       |
| OS  | Windows 11 Home                             |

ノート PC の RTX 3060 は **6GB**。デスクトップ版(12GB)とは別物で、初期検討で混同しかけて軌道修正した。

## 採用 LLM

| ランク  | モデル                                               | 役割                                | 量子化    | VRAM 想定  |
|------|---------------------------------------------------|-----------------------------------|--------|----------|
| ★★★★ | huihui_ai/qwen3-abliterated:4b                    | 本番採用( think: false で thinking 抑制) | Q4_K_M | 約 3.5 GB |
| ★★   | huihui_ai/llama3.2-abliterate:3b                  | 大集団保険(JSON 速度最強)                  | Q4_K_M | 約 2.5 GB |
| ★    | huihui_ai/dolphin3-abliterated:8b-llama3.1-q4_K_M | 品質候補(速度ネック)                       | Q4_K_M | 約 4.7 GB |

選定の遠回りは 05 章「abliterated 採用までの検討経緯」と「Llama 一度試したが品質不足で戻した話」に書いた。

## なぜ Uncensored(abliterated)を選んだか

通常モデルは拒否率が高く、「嘘をつく」「派閥に分裂する」「反乱を起こす」などの観察対象が**そもそも発生しない**。abliteration によって倫理ガードを外すことで、創発を素直に観察できる。NG ワードフィルタは Python 側で別途挟む方針。

## 5 種類のログ + エコー検証パイプライン

| ログ                     | 内容                                             | 使い道               |
|------------------------|------------------------------------------------|-------------------|
| messages.jsonl         | 全発話・受信(step / from / to / message / reasoning) | 創発観察(04 章)+ エコー検証 |
| events.jsonl           | place_change、memory_added、memory_evicted など    | 創発指標(03 章)        |
| memory_reasoning.jsonl | エージェントの内面ログ(reasoning 抽出)                      | 04 章の解釈用          |
| metrics.json           | gini / pair_stability / silent_rate などの集計      | 03 章              |
| run_metadata.json      | seed / model / agents / scenario_label など      | 再現性確認             |

加えて、Phase 5 で **エコー検証パイプライン** を恒久化:

| スクリプト                                                      | 目的                                                                                               |
|------------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| docs/04_モデル検<br>証/conversation_check/check_conversation.py | 4 指標(echo_mean / echo_max / reflection_mean / self_similarity)を <code>messages.jsonl</code> から算出 |
| docs/04_モデル検<br>証/conversation_check/find_echo_examples.py | 完全コピペ・膠着の具体例を抽出                                                                                  |

「エージェントが本当に会話しているか」を毎回機械的に判定できる仕組み。詳細は § 3 / § 4。

「あとで分析するためのログ」ではなく「**創発を見つけるためのログ**」として最初から設計した。

## シナリオ駆動

各シナリオは `config/scenario_*.yaml` で表現する。`extends:` で他 yaml を継承して `deep_merge` するため、**創発イベントや集団サイズの差分だけ書ける**。Phase 5 主役の `scenario_alien_5.yaml` の例:

```
extends: "base.yaml"

simulation:

  duration: 15

agents:

  num_agents: 5

places:

  - name: "main_office"

  ...

events:

  - type: "alien"

  start_step: 1

visualization:

  save_frames: true
```

`base.yaml` には共通の **MBTI ペルソナ(年齢 20-60 / 性別 / 9 国籍プール / MBTI 16 型)** + LLM 設定 (Qwen3 4B + temperature 0.8 + max\_tokens 100)が入っており、各シナリオで上書きしたい部分だけ書く。

100 体版( `scenario_alien_100.yaml` など、粉川氏マシン用)は `scenario_alien_5.yaml` を継承して `num_agents: 100` + `llm.model: "huihui_ai/qwen3-uncensored:34b"` を上書き。

旧 4 象限の yaml(`scenario_local_`, `scenario_urban_`, `scenario_prod_*`)は `config/legacy/` に残置しており、副産物としての参考データ用。

## 検証結果

提出時点で完走している本番ランは:

- **Phase 4-A 旧 4 象限**(参考データ、2026-04-30 早朝):4 シナリオ × 各 1 試行
- **Phase 5 新軸 5 体ラン**(2026-04-30 夜、本提出の主演):宇宙人 / 無重力 各 1 試行
- **Phase 5 新軸 100 体ラン**:粉川氏マシンで実走中(完了次第差し替え)

LLM は **Qwen3 4B abilitated** + `think: false` (M-05 / M-06 / M-08 / M-09 / M-10 適用済)。100 体版は粉川氏マシンで Qwen3 34B Uncensored を使用予定。

### 「会話の質」を巡る発見と段階的改善

提出版の数値結果を読む前に、**初稿で何が起きていたか**を共有する必要がある。これが本提出版の核心である。

#### 3.1 初稿(Phase 4-A)で発覚したエコー問題

旧 4 象限ランの `messages.jsonl` を機械的に分析したところ、**4 つの異常値**が観測された:

| 指標                                             | 健全レンジ   | 観測値                     | 意味          |
|------------------------------------------------|---------|-------------------------|-------------|
| <code>echo_max</code> (同 step での発話完全一致度)       | < 0.3   | <b>1.000</b> (全 4 シナリオ) | 一字一句コピペ     |
| <code>echo_mean</code> (平均ペア類似度)               | < 0.2   | 0.336                   | 全員似た表現      |
| <code>reflection_mean</code> (受信文との重複)         | 0.1~0.3 | 0.705                   | 受信文をそのままコピー |
| <code>self_similarity</code> (連続 step での同一発話率) | < 0.3   | 0.422                   | 同じことを繰り返す   |

完全コピペの実例(prod\_local\_startup step 5)

Agent 1 → Agent 2: 「景気の悪さと予算の緊張感は、みんな同じ気持ちだと思います。

他の部署と連携しながら、効率的な働き方やコスト削減の方法を一緒に探していきましょ

う。

main\_office はまだ空いており、必要があれば、ぜひ声をかけましょう。」

Agent 2 → Agent 0: ↑と一字一句同じ

→ これは「会話している」のではなく「同じテキストが伝染している」だけだった。

3.2 4 段階の対策と効果

| 段階                          | 主な対策                                                               | echo_mean | echo_max | reflection_mean | self_similarity |
|-----------------------------|--------------------------------------------------------------------|-----------|----------|-----------------|-----------------|
| BEFORE(Phase 4-A)           | 旧設定                                                                | 0.336 ❌   | 1.000 ❌  | 0.705 ❌         | 0.422 ❌         |
| A(M-08)                     | プロンプト<br>粒度 /<br>max_tokens<br>512→100 /<br>temperature<br>0.5→0.8 | 0.043 ✅   | 1.000    | 0.666 △         | 0.163 ✅         |
| B(M-09)                     | MBTI / 年<br>齢 / 国籍 ラ<br>ンダム +<br>MBTI を冒<br>頭配置                    | 0.021 ✅   | 1.000    | 0.033 ⚠️ (無視)   | 0.093 ✅         |
| C(alien_5)(M-10)            | 宇宙人イベ<br>ント注入                                                      | 0.012 ✅   | 0.889    | 0.138 ✅         | 0.027 ✅         |
| C(zero_gravity_5)<br>(M-10) | 無重力イベ<br>ント注入                                                      | 0.003 ✅   | 0.333 ✅  | 0.134 ✅         | 0.013 ✅         |

4 つの指標すべてが健全レンジに到達。特に zero\_gravity\_5 で echo\_max=0.333 を達成し、初めて 1.000 から離脱した。

3.3 段階別の貢献

各対策が何を解決したか:

| 対策(段階)          | 解決したもの                                                                 |
|-----------------|------------------------------------------------------------------------|
| プロンプト粒度(A-1-1)  | コピペ誘発を断つ。 <code>MESSAGES FROM OTHERS</code> を「直近 1 件 + 引用 + 自分の言葉で」に粗化 |
| 短文化(A-1-3)      | <code>max_tokens</code> 512 → 100。長文要求で定型句に逃げるループを断つ                   |
| 多様性温度(A-1-4)    | <code>temperature</code> 0.5 → 0.8。多様な語彙を引き出す                          |
| MBTI / 国籍多様性(B) | エージェント個性の入り口。reflection 過小化が起きるが、C で復元                                 |
| 創発イベント(C)       | 状況依存の反応を引き出す。「会話のアンカー」を提供して reflection を健全レンジに戻す                       |

→ A → B → C の順番で重ねたから何が効いたか切り分けられた。一発で全部入れていたら原因が特定できなかった。

## 5 体ランの結果(Phase 5 主役)

### 3.4 比較表

| run                    | イベント | n | step | msgs | gini | top_share | pair_stab | silent |
|------------------------|------|---|------|------|------|-----------|-----------|--------|
| prod_v2_alien_5        | 宇宙人  | 5 | 15   | 61   | 後述   | 後述        | 後述        | 後述     |
| prod_v2_zero_gravity_5 | 無重力  | 5 | 15   | 62   | 後述   | 後述        | 後述        | 後述     |

### 3.5 発話例で見る個性化(MBTI に呼応)

宇宙人シナリオ step 1(同じイベントへの 5 通りの初動反応):

|                      |                |              |
|----------------------|----------------|--------------|
| Agent 0 (インド, 25歳):  | 「少しの変化が楽しみです」  | ← 好奇心 / 期待   |
| Agent 1 (インド, 55歳):  | 「未知の存在に注目する」   | ← 冷静 / 観察    |
| Agent 2 (ブラジル, 48歳): | 「未来は今ここに 있습니다」 | ← 哲学的 / 現在志向 |
| Agent 3 (ドイツ, 47歳):  | 「静かな屋」         | ← 落ち着き / 距離  |
| Agent 4 (ドイツ, 33歳):  | (この step は沈黙)  |              |

無重力シナリオ step 1:

Agent 0: 「重力のない世界は、自由だ」(肯定的 / 解放感)

Agent 1: 「重力はもういい」(受容 / 諦観)

Agent 2: 「希望」(楽観)

Agent 3: 「静かに動け」(慎重 / 助言)

Agent 4: (省略)

→ Phase 4-A の旧本番ラン(全員「景気の悪さはコスト削減を」と定型句)とは質的に異なる。同じ状況に対して、5通りの違う角度から反応している。

## 比較軸 1 — 規模を変えると何が変わるか(参考データ:旧 4 象限)

旧 4 象限は提出主役ではないが、「規模 → 派閥固定」「規模 → 沈黙」というパターンは副産物として観測できた。これは Phase 5 で 100 体ランが完走した時に再検証する。

| 指標               | 5 agents 平均 | 10 agents 平均 | 変化     |
|------------------|-------------|--------------|--------|
| 沈黙率(silent_rate) | 0.00        | 0.25         | +25 pt |
| gini             | 0.054       | 0.319        | +0.265 |
| pair_stability   | 0.808       | 0.910        | +0.102 |

ただし 3.1~3.2 で示したとおり、この観察自体がエコーの上に立っていた可能性がある。Phase 5 の改良後設計で 100 体を回した結果が出たら再評価する(06 章未解決)。

## 比較軸 2 — 創発イベントを変えると何が変わるか(Phase 5 中心)

宇宙人 vs 無重力 で echo\_max が大きく違う (0.889 vs 0.333):

- 宇宙人は LLM がよく知っている話題(SF / コンタクト) → 関連語彙は豊富だが「未知への反応」のフレーズが反復しやすい
- 無重力は LLM があまり扱わない物理崩壊シナリオ → 短い感嘆や即興的な発話が増え、定型化しにくい

→ 「LLM の語彙の偏り」が創発の質を左右するという、設計時には予測できなかった発見。

## 解釈

- エコー問題の発見と修正そのものが提出物の核。数値の改善より、「初稿で見えていた創発」が実体は再生産だったと特定して修正したプロセスが本質

- 創発の真の観察には、ペルソナの個性化(MBTI)+ 状況のアンカー(イベント)の両方が必要だった
- 旧 4 象限の数値結果(規模で派閥)はエコー前提なので、Phase 5 改良版での再検証が必須(06 章)
- 100 体 × Qwen3 34B のラン結果(粉川氏マシン側)は、本提出版の続報として共有予定

## 創発観察

本章は **実ログの会話抜粋 + 動画フレーム** を中心に構成する。生の発話を消したり整形したりしない。出典: `output/prod_v2_alien_5/` / `output/prod_v2_zero_gravity_5/` (各 30 step、step 15 でイベント発火)

旧 Phase 4-A 観察(エコー前提のため疑わしい)については § 3 検証結果を参照。

### 4.1 イベント途中発火による「日常 → ピボット」の観察

最大のシナリオ設計上の改良は **イベント** を **step 1** ではなく **step 15(中盤)** で **発火** させたこと。前半 14 **step** は通常の業務会話、**step 15** で突発的に**宇宙人 / 無重力が来る** 構造で、agent が日常モードからどう切り替わるかを観察する。



#### 4.1.1 alien\_5 — 日常 → UFO 着地への反応

[step 13(発火 2 ステップ前)]

a3 → a2: 「ドローンの飛行状況を確認できるモニタの場所を教えてくださいませんか？」

他の場所でも確認可能なんですか？」

[step 14(発火直前)]

a4 → a2: 「ドローンの飛行状況を確認できるモニタの場所を教えてくださいませんか？」

他の場所でも確認可能なんですか？」

[step 15(★ UFO 着地点 (-15, 12) で発火 ★)]

a0 → a2: 「今、UFOが(-15, 12)の近くを通りました。main\_office では 5 人いて、

ドローンの飛行も確認しました。今後はどこを確認すべきですか？」

a2 → a0: 「UFO の動きを確認するために、小会議室 A のモニタをもう少し詳しく

見てみたいと思います。他の場所でも確認できるか教えてくださいませんか？」

解釈:

- 発火直後の step 15 で agent 0 が **UFO の座標 (-15, 12) を発話に取り込んだ**。これは prompt の `events.alien.position` を LLM が読んで自分の言葉に置き換えた直接証拠
- 「ドローン」と話していた agent 2 が **「UFO の動きを確認したい」** に切り替わった = 日常モードから状況対応モードへピボット
- LLM に「移動しろ」とは指示していないが、続く step 17-25 で物理的に **agent 3 / agent 0 が main\_office を退出**、agent 4 はフィールド境界に向かう動き (`events.jsonl` の `place_change / clamp_to_field` イベントで確認可能)

### 4.1.2 zero\_gravity\_5 — 物理崩壊への反応

[step 13]

a1 → a4: 「ホワイトボードの端が曲がっている thing について、

少し詳しく教えていただけますか？」 ← 偶然か、空間の歪みの前兆か？

[step 15(★ ZERO GRAVITY STARTED! ★)]

[詳細は messages.jsonl を参照、本資料では概要のみ]

step 13 で偶然「ホワイトボードの端が曲がっている thing」という発話が出ているのは興味深い。  
seed=42 固定で同じ条件で再走させて再現するか、または別 seed で消えるかが今後の検証課題。

## 4.2 視覚化フラッシュ — 発火タイミングを動画で見せる

ユーザフィードバック「無重力になったタイミングがわかりやすくしたい」に対応して、**発火 step だけ特別な視覚的フラッシュ**を入れた。

| 状態            | alien                                                  | zero_gravity                                                 |
|---------------|--------------------------------------------------------|--------------------------------------------------------------|
| 発火 step (=15) | 赤い大ハロ + 拡大 UFO + 上部に「👁️ ALIEN ARRIVED at (X, Y)!」黄色バナー | 赤太枠 + フィールド全体に薄い赤オーバーレイ + 「⚠️ ZERO GRAVITY STARTED! ⚠️」黄色バナー |
| 発火後 step      | 紫小ハロ + 通常 UFO + 「👁️ alien_0 (着地+N)」(N = 経過 step)       | 青枠 + 「⚠️ ZERO GRAVITY (step 15~ / +N) ⚠️」                    |

PNG ファイルサイズで定量化すると、step 14 と step 15 で **+26~44%** の差(フラッシュ効果)が出ている。

実装:src/viz/visualizer.py `_draw.aliens` / `_draw.zero_gravity` で `current_step == activated_step` を判定。

## 4.3 動く UFO — イベントが「動的なオブジェクト」になる

参考実装の火事は **位置固定**(着地点に張り付いている)だったが、本提出版では UFO がランダムウォーク( $\pm 2/\text{step}$ )で動く。理由は「LLM agent が動く UFO に追従しようとする創発」を観察したかったため。

実装は `src/events/alien.py` の `maybe_move(rng)`。ただし UFO の判断は LLM ではない(=Python の random walk)。これは設計判断:UFO の意図を LLM に推測させないことで、agent が「異物」として観察・反応する立場を保つため。

実走では、`(-15, 12)` で着地した UFO が step 20 時点で `(-16, 9)` まで移動。agent の発話も「UFO が `(-15, 12)`」(step 15)→「UFO の動きを確認」(step 16)→「UFO が移動している方向へ進み、その動きを観察」(step 17、別ラン)のように、移動を踏まえた表現が観察された。

## 4.4 沈黙 — 規模が押し付ける役割分化(5 体でも観測)

5 体 × 30 step で発話量を集計すると、Phase 4-A と同じパターン:

- 一部の agent が極端に少ない発話(`prod_v2_zero_gravity_5` では step 22-24, 26-28 で発話 0 件の step がある)
- `conversation_profiles` を入れたことで「役割」がついたが、それでも沈黙が消えるわけではない

解釈:LLM の意思以前に、3 階(物理)の `communication_radius` 制約 = 「同じ place の通信半径内に他 agent がいない」ことが沈黙を生んでいる。これは Phase 4-A 旧本番ランでも観測できた性質で、規模に依存しない頑健な創発。

## 4.5 観察できなかったもの(Phase 5 改良版でも未到達)

- 嘘 — 自己保存の動機がない(責任を回避する状況なし)
- 通貨 — 1 階に「アイテム所持・交換」が未実装
- 反乱 — 報酬・罰のループが 3 階にない
- 明確な対立構造 — 5 体で 30 step では集団が小さく、対立軸が立ち上がる前にイベント反応で発話が消費される

→ 100 体ラン(粉川氏マシン側)で観察できる可能性が高い。

## 4.6 観察の限界(率直に)

- N=1 試行:5 体 × 各イベント 1 ラン。同 seed の再現性は確保されているが、統計的有意性は主張できない
- 数値指標は悪化(M-10 比で `echo_mean`、`reflection`、`self_similarity` すべて上昇):duration を 15 → 30 に倍増し前半パートが長くなったこと、`conversation_profiles` で役割を強く与えたことが副作用として効いている。質的観察(発火後のピボット、UFO 座標参照、物理移動)は明確に出ているので数値そのものより観察の中身を信じる
- `conversation_profiles` の演劇化:M-11 自然会話と役の問題で議論された「役を演じさせない」設計に向けて `personal_context` への置き換えが今後の改善

## 4.7 最大の発見(率直)

「初稿の観察」が実体はエコー誤認だった、という気付き (§3 で既に詳述)に加えて、本 Phase 5 v1.1 では:

- イベント途中発火で「日常 → ピボット」が動画でも数値でも観察できた
- LLM agent が prompt に注入された UFO 座標を発話で参照する(prompt 設計が直接的に発話に効くことの定量証拠)
- 動く UFO が、agent の物理移動 + 発話の両方で追従反応を引き出す

→ 提出後に 100 体ランの結果が来たら、再度 conversation\_check で同じ品質判定を行い、規模が大きくなった時のピボット様式を比較する。

## 頑張った点

審査員に伝えたいのは、技術スタックの自慢ではなく「何を考え、何を試し、何を捨てたか」。本プロジェクトでは特に「初稿で気づいた問題を上から順に潰した過程」を見ていただきたい。

## 5.1 比較設計の枠組み

「LLM が動くシミュレーション」を作るのは難しくない。難しいのは **何を比較すれば創発の差が見えるか** の設計である。本プロジェクトでは以下の軸を独立に動かせるよう config 化した:

1. 創発イベント(宇宙人 / 無重力 / 火事 / なし) — `events`: セクションで type 判別
2. 集団サイズ(5 / 100) — `agents.num_agents`
3. MBTI 分布(全 16 型 / 偏り設定可) — `agents.persona.mbti.values`
4. 国籍分布(プール抽選) — `agents.persona.nationality.pool`
5. 景気(`good` / `neutral` / `bad`) — `environment.economy`
6. LLM モデル(Qwen3 4B / 34B / Llama 3B / Dolphin 8B) — `llm.model`

各軸は他軸を固定して動かせる設計にした(yaml の `extends` チェイン + `deep_merge`)。

## 5.2 失敗・没案

### 5.2.1 Llama 3.2 3B に乗り換えて戻した

- 当初は **速度を狙って Llama 3.2 3B abliterate** に prod 切替(M-04 横並び検証で JSON 出力が最速 2.4 秒だったため)
- 実走させると **日本語にローマ字・英単語が混入**(「景気が悪い」が「keiki ga warui」になる、「会議室」が「kaigi-shitsu」になる)。提出品質に届かず

- **判断:**「速度より日本語品質」を優先し、Qwen3 4B + `think: false` に戻した。Qwen3 は M-05 で eval\_count を 17 倍効率化できたので、速度差は縮まる
- **学び:**JSON 出力品質と長文日本語品質は別の評価軸。横並び検証(M-04)では JSON だけ見ていて長文を見ていなかった

### 5.2.2 Qwen3 abilitated の中国語混入(M-06)

- Llama から Qwen3 に戻した直後、最初の本番ランで **発話が全て中国語**( 大家好, 最近公司资金紧张... )になる事象が発生
- 原因:システムプロンプトが英語ベース、ペルソナだけ日本語 → Qwen3 が母語(中国語)バイアスに流れた
- **対処:** `_build_persona_section` に `=== LANGUAGE REQUIREMENT (CRITICAL) ===` セクションを追加。BEFORE/AFTER 各 3 試行で BEFORE 3/3 中国語 → AFTER 0/3 を確認(M-06)
- **学び:**abilitated モデルは安全層と一緒に「言語選択の慎重さ」も削れている可能性。「日本語で出てくる」を当然視せず、**毎回検証する**ルールに

### 5.2.3 Qwen3 の `/no_think` プロンプトが効かなかった(M-05)

- `/no_think` を user 末尾 / 先頭 / system に挿入する 3 通りを試したが、いずれも thinking ブロックが残る
- Ollama 0.21+ の `think: false` **API パラメータ**が正解だった(M-05)
- eval\_count: 447 → 26(17 倍効率化)
- **学び:**プロンプト工夫を試す前に、API レイヤのフラグを確認すべきだった

### 5.2.4 初稿の本番ランがエコーまみれだった(本提出版を分けた最大の問題)

これは「失敗」というより、ハッカソン提出物の核となる発見である。

- 旧 4 象限の本番ラン(Phase 4-A)を完走させ、PDF を v0.9 として組み上げた
- ユーザの「**1 人 1 人のエージェントが同じようなことを言っているように見える**」という直感的観察を実データで検証
- 結果:**全 4 シナリオで `echo_max=1.000`** (同 step での別 agent 完全コピー)、  
`reflection_mean=0.705` (受信文の単純コピー)
- **対処:**プロンプト粒度 → MBTI ペルソナ → 創発イベントの 3 段階で対策(M-08 / M-09 / M-10)
- **学び:**指標が綺麗に出ていても、生ログを読まないと“観察できているように見える誤った観察”が量産される。エコー検証スクリプト(`conversation_check`)を Phase 5 で恒久化した

### 5.2.5 議事録改訂の認識遅れ(プロセスの失敗)

- 2026-04-29 の議事録で **比較軸が「集団サイズ × 創発イベント」に刷新**(4 象限切り廃止)されていたが、私(Claude)は議事録を読まずに旧設計で本番ラン + PDF を実行
- 結果:**約 4 時間分の計算と PDF v0.9 が「議事録ベースだと未着手」状態に**

- **対処:**問題点リスト §6 プロセス改善 に再発防止策を記録。本番ラン前に「直近 24 時間以内のミーティング議事録を確認する」チェックリストを規定
- **学び:**設計書 / 議事録 / 実装の整合は実装前に取る。事後対応で取り戻すコストはこれから先のラン全部に乗っかる

### 5.2.6 ablated を選ぶまでの遠回り

- 当初は **日本語性能優先で JP 系モデル**(ELYZA、Stockmark など)を本命視した
- しかし JP 系には **uncensored 版が存在しない**ことを LLM 選定 §04 で確認
- 通常モデルでは「嘘」「派閥」「反乱」が **拒否されて発生しない**ことが小規模実験で判明
- 議論の末、**ablated 系**(`huihui_ai/*`)を採用。日本語は Qwen3 でカバー
- 詳細: `docs/01_設計書/02_LLMモデル/2026-04-24_選定と推奨/04_選定の前提.md`

### 5.2.7 6GB VRAM への現実適応

- 当初「7B~14B でいける」と楽観 → 6GB では Q4 でもギリギリ
- KV cache、ctx 長、並列度を全部削って **3~4B + Q4\_K\_M** に着地
- 100 体本番は粉川氏マシン側で Qwen3 34B Uncensored を使う二段構え

## 5.3 技術的挑戦

- **3 階層モデルの責任分離:**1 階(物)・2 階(環境)はプロンプト、3 階(物理)は Python 側で強制という設計境界を最初に引いた。LLM に「行動指示」を書かないので、観察された創発は「シナリオの仕掛け」ではなく「状態に対する agent の自発的反応」である
- **エコー検証パイプライン:**`messages.jsonl` から 4 指標(`echo_mean` / `echo_max` / `reflection_mean` / `self_similarity`)を機械的に算出し、対策前後の比較を定量化する基盤を構築
- **シナリオの extends チェイン:**`base + scenario + prod_*`を `deep_merge` する仕組みで、軸の組み合わせを 15 行程度の差分 yaml で表現可能
- **動画化:**`matplotlib`(Agg backend)で各 step を PNG → `ffmpeg` で mp4 化。Windows でも完全動作。`tools/generate_video.py` の薄いラップで再現可能
- **Edge headless での PDF 化:**LaTeX なしで Pandoc + Microsoft Edge headless によって PDF を生成(本 PDF 自体がその出力)。OS の組み込みコンポーネントだけで動くポータブル経路

## 未解決課題

ハッカソン提出時点で**未解決**の項目を、誤魔化さずに列挙する。

## 6.1 試行回数の不足(N=1 試行のまま)

- Phase 5 主役の 5 体ランは **宇宙人 1 試行 + 無重力 1 試行のみ**。同 seed 固定なので再現性はあるが、**統計的有意性は主張できない**
- 100 体ランは粉川氏マシン側で実走中。完走しても各シナリオ 1 試行
- **改善案**: 同 config で seed を 5~10 通り振った試行群を作る。1 試行 約 12 分 × 5 通り × 2 イベント = 約 2 時間

## 6.2 100 体 × Qwen3 34B の結果が未到着

- Phase 5 の本命である **100 体 × Qwen3 34B Uncensored × 創発イベント** の結果はまだ届いていない(粉川氏マシン側で実走中)
- 完了次第、本 PDF と一緒に提出物として差し替え予定
- **改善案**: docs/05\_運用手順/粉川氏向け\_100体ラン手順.md に従って実行 → 結果を `output/prod_v2*_100/` に置いて main にマージ

## 6.3 旧 4 象限結果のエコー疑惑(再評価が必要)

- § 3 で示したとおり、旧 Phase 4-A の本番ラン 4 シナリオは **echo\_max=1.000(全 4 シナリオでコピペ)** だった
- これにもかかわらず gini や pair\_stability では「規模で派閥が固定化」「沈黙率が 25%」のような綺麗な対比が見えていた
- **疑惑**: エコー前提の発話分布が、見かけの派閥構造を作っていた可能性
- **改善案**: Phase 5 改良版(エコー対策後)で同じ 4 象限を再ランして、対比が再現するかを検証。**1 試行あたり約 25~50 分 × 4 シナリオ × 5 seed = 8~16 時間**

## 6.4 観察できなかった創発(嘘 / 通貨 / 反乱 / 明確な派閥)

- 5 体・15 step では **agent が“対立”する文脈を作れていない**(資源の取り合いがない、役割対立がない)
- **改善案**:
  - **嘘**: 火災シナリオを再導入(参考実装ベース)。「自分の責任を回避するために嘘をつく」状況を作る
  - **通貨**: 1 階に「アイテム所持・交換」を追加。アイテム X が交換媒体として何 step 目から機能し始めるか観測
  - **反乱**: 報酬・罰のループを 3 階に実装。役職階層がある中で、平社員が連帯して規則違反する条件を探す
  - **派閥**: 100 体 × 長 step で観察できる可能性が高い(Phase 4-A でも 10 体で `pair_stability=0.94` が出ていた、ただしエコー疑い)



## 6.5 創発指標の主観性

- 「派閥」の判定 = `pair_stability ≥ 0.85` という閾値判定は、**経験則**であり理論的根拠はない
- 「合意形成」と「単なるエコー(同じフレーズの反復)」を機械的に区別する仕組みは作ったが (`echo_mean` / `reflection_mean`)、**この対比自体が正しいかは別途検証が必要**
- **改善案**:別 LLM(GPT-4o / Claude Sonnet 4.6)に `messages.jsonl` 全体を渡し、(a) 派閥クラスタリング、(b) 「嘘」「合意」「反乱」のラベル付けを盲検で実施。本観察(タコ + 自動指標)とのキャップ係数を見る

## 6.6 MBTI が創発に効くかは未確認(検証コスト)

- Phase 5 の MBTI ペルソナで「ISFP の Agent 1 が“静かに生きている”と発話」のような **個性化のサンプル**は観察できた
- ただし **MBTI を統制した対照実験**(全員 ENFP / 全員 INTJ などと比較)はやっていない。N=1 で「らしさ」を語っても説得力が薄い
- **改善案**: `config/scenario_mbti_uniform_*.yaml` を作って、MBTI 単一型を 5 体 × 全 16 型で回す。1 試行あたり 12 分 × 16 型 × 2 イベント = 約 6 時間

## 6.7 6GB VRAM 由来の制約

- `num_ctx` が小さく、長期記憶を持ってない
- 100 step を超えると **早期の出来事が文脈から抜ける**
- `AgentMemory(LRU)` で要約を挟む実装はあるが、本番投入が時間切れで限定的
- **改善案**:認知限界 LRU の効果検証 run を別途。 `cognitive_limit=∞` vs `cognitive_limit=10` の差分を可視化

## 6.8 動画の網羅性

- 提出 mp4 は宇宙人 / 無重力 各 1 試行のみ
- **改善案**:創発指標 top-K の run を自動選定するスクリプトを追加(指標ベースの選定で、見栄えと再現性を両立)

## 6.9 ペルソナのバイアス

- 「30 代の男性 / 国籍: ブラジル / MBTI: ENFP」の組み合わせ自体が **LLM 側の社会通念バイアス**を呼び起こす
- 観察対象でもあるが、独立変数として扱うには「ペルソナを与えない群」との比較が必要
- **改善案**:同シナリオで `persona_fragment=""` (無記述)を対照群として走らせ、差分を見る



## 6.10「もし API ハイブリッドが許されたら」

- ローカル 6GB に閉じ込めた制約から、Claude Haiku / Gemini Flash の API を併用する設計は持っているが本番未投入
- API 併用なら 100 体 × 100 step + 10 試行 が 数時間で完走可能
- ハッカソン規約次第で投入を検討

## 今後の展望

### 他シナリオへの拡張

3 階層フレームワークは、1 階(物)を入れ替えるだけで別の題材に転用できるように設計してある。優先度の高い拡張先:

| シナリオ  | 1 階        | 2 階      | 3 階          | 観察したい創発      |
|-------|------------|----------|--------------|--------------|
| 細胞    | 細胞器官・栄養    | 組織・血流    | 拡散・分裂        | 自己組織化、がん化    |
| 虫     | 体・触角・フェロモン | 巣・餌場     | 重力・風         | スウォーム、分業     |
| 人(現行) | 身体・場・所持物   | 場所・天候・景気 | 通信距離・遮断・認知限界 | 嘘・派閥・通貨・合意形成 |
| ウイルス  | 表面タンパク・RNA | 宿主・免疫系   | 拡散・変異        | 株間競争、エスケープ   |

優先度 1 位:虫(スウォーム)。1 階の概念差(身体 → 触角・フェロモン)が大きく、フレームワークの汎用性を最も強く示せる。同じ 3 階(物理)コードがそのまま使える。

### 提出後すぐ着手するもの(優先順)

- N=5 試行に増やす(4 象限すべて)。pair\_stability の差が有意かを統計検定で確認
- 男女比 5 段階 × N=5(設計済み、本番未投入)
- 嘘シナリオ(火災 + 責任回避)を再投入。messages.jsonl から「嘘発話」を別 LLM で抽出
- API ハイブリッドで 100 体規模を試す。VRAM 枠を抜けた時に何が変わるか

### モデル拡張

- API ハイブリッド(Claude Haiku 4.5 / Gemini Flash / Grok)を OllamaClient と同じ OpenAI 互換 インターフェースで切替可能に( base\_url だけ差し替え)

- **MoE 系**(Mixtral 等)で「専門家エージェント」を表現する案。役職ペルソナと組み合わせる

## 規模拡張

- 100 人 → 1000 人。VRAM/帯域の支配項が変わるため、3 階の `communication_radius_overrides` を空間分割インデックスに置き換える必要あり
- マルチノード(別 PC 2 台で半分ずつ受け持つ)。1 階の place 配置を共有してネットワーク経由で `attempt_move` を交換

## 公開プラン

- リポジトリ: <https://github.com/Kai-85-git/singulab>
- 議事録・要件定義・LLM 選定検討・没案も含めて公開する立場
- 失敗例こそ価値があるという立場(05 章「失敗の書き方」と同じ理由)
- 提出後 1 週間以内に N を増やしたデータセットを公開予定