

Singulab — 集団構成パラメータと創発を観察する

LLM 多体シミュレーションによる仮説検証レポート

Kai、タコ

2026-05-07

Contents

1	思想と背景	3
1.1	何を観察したかったか	3
1.2	参考実装と何が違うのか	3
1.3	3 階層モデル	3
1.4	なぜハッカソンに出すのか	3
2	システム構成	3
2.1	全体アーキテクチャ	3
2.2	ハードウェア	4
2.3	採用 LLM	4
2.4	なぜ Uncensored(abliterated)を選んだか	4
2.5	5 種類のログ	4
3	検証結果	5
3.1	性能指標サマリ	5
3.2	比較軸 1 — モデルを変えると何が変わるか	5
3.3	比較軸 2 — 男女比を変えると何が変わるか	5
3.4	比較軸 3 — 人種・年齢を変えると何が変わるか	5
3.5	グラフ	5
3.6	解釈	6
4	創発観察	6
4.1	嘘 — 自己保存のための虚偽報告	6
4.2	派閥 — 構成属性に沿った分極	6
4.3	通貨 — 自然発生する交換単位	6
4.4	反乱 — 規則違反の連鎖	6
4.5	合意形成 — 多数決とは異なるダイナミクス	6
4.6	発言権 — 誰が場を支配したか	6
4.7	観察の限界	6
5	頑張った点	6
5.1	比較設計の枠組み	6
5.2	失敗・没案	7
5.3	技術的挑戦	7

6	未解決課題	7
6.1	統計的有意性の不足	7
6.2	ペルソナのバイアス	7
6.3	6GB VRAM 由来の制約	8
6.4	創発指標の主観性	8
6.5	動画の網羅性	8
7	今後の展望	8
7.1	他シナリオへの拡張	8
7.2	モデル拡張	8
7.3	規模拡張	8
7.4	公開プラン	9

Singulab

集団構成パラメータと創発の関係を観察する

LLM 多体シミュレーションによる仮説検証レポート

Kai、タコ

github.com/Kai-85-git/singulab

2026-05-07 v1.0

1 思想と背景

1.1 何を観察したかったか

本プロジェクトの問いは一つ。

エージェント集団の構成パラメータ(LLM モデル / 男女比 / 人種 / 年齢)を変えると、創発(嘘・派閥・通貨・反乱・合意形成・発言権)はどう変わるか。

LLM ベンチマークでも、シミュレーション基盤の披露でもない。比較実験それ自体が主役である。同じシナリオを、構成だけ差し替えて何度も走らせ、創発の差を観察する。

1.2 参考実装と何が違うのか

参考にした [2d-multi-places-simulation-on-fire-public](#) は「火災発生時の避難挙動」をシナリオとして固定していた。本プロジェクトは:

- シナリオを差し替え可能にした(2階フレームワーク)
- エージェントの内面パラメータを比較軸に格上げした(モデル種別、性別、人種、年齢、ペルソナ)
- 創発観察ロギングを最初から組み込んだ(jsonl × 5)

1.3 3 階層モデル

議事録 § 6.6 で合意した階層フレームワークを設計の骨格に置いた。

階	担当	実装
1 階(物)	エージェントの身体・所持物・能力	プロンプト
2 階(環境)	場所・天候・時間・近傍関係	プロンプト
3 階(物理)	重力・通信距離・近傍発話の遮断	Python 側で強制

LLM に「行動指示」を書かない。状態だけ渡し、行動は出てくるに任せる(議事録 § 4「命令最小」方針)。

TBD: 当該章の図はビルド時に [docs/01_設計書/06_システム設計/01_アーキテクチャ概要/](#) の Mermaid を埋め込み。

1.4 なぜハッカソンに出すのか

「創発を観察する」というテーマは、実装を完成させなくても観察結果が出れば価値が成立する特殊な題材である。本レポートはその観察記録であり、完成品の自慢ではない。

2 システム構成

2.1 全体アーキテクチャ

graph TB

```
Sim[Simulation Engine<br/>100 エージェント × 100 ステップ] --> AC[AsyncLLMClient<br/>OpenAI 互換 + Se  
AC --> Ollama[Ollama localhost:11434]  
Ollama --> Q[Qwen3 4B abliterated]  
Ollama --> L[Llama 3.2 3B abliterated]
```

```

Sim --> RL[RunLogger]
RL --> L1[(llm_io.jsonl)]
RL --> L2[(perf.jsonl)]
RL --> L3[(vram.jsonl)]
RL --> L4[(events.jsonl)]
RL --> L5[(emergence.jsonl)]

```

2.2 ハードウェア

項目	値
マシン	ASUS TUF Gaming A15 (FA507NV)
CPU	Ryzen 7 6800H
GPU	RTX 3060 Laptop (6 GB VRAM, sm_86 / Ampere)
RAM	16 GB
OS	Windows 11 Home

ノート PC の RTX 3060 は 6GB。デスクトップ版(12GB)とは別物で、初期検討で混同しかけて軌道修正した。

2.3 採用 LLM

ランク	モデル	役割	量子化	VRAM 想定
★★★	huihui_ai/qwen3-abliterated:4b	メイン(中国系・日本語良好)	Q4_K_M	~3.5 GB
★★★	huihui_ai/llama3.1-abliterated:3b	100 人大集団用	Q4_K_M	~2.5 GB
★	huihui_ai/dolphin3-abliterated:8b-llama3.1-q4_K_M	品質検証(stretch)	Q4_K_M	~4.7 GB

選定根拠の詳細は [docs/01_設計書/02_LLMモデル/2026-04-24_選定と推奨/](#) を参照。

2.4 なぜ Uncensored(abliterated)を選んだか

通常モデルは拒否率が高く、「嘘をつく」「派閥に分裂する」「反乱を起こす」などの観察対象がそもそも発生しない。abliteration によって倫理ガードを外すことで、創発を素直に観察できる。NG ワードフィルタは Python 側で別途挟む。

詳細: 05 章「abliterated 採用までの検討経緯」

2.5 5 種類のログ

ログ	内容	使い道
llm_io.jsonl	プロンプト全文と応答全文	創発観察(04 章)
perf.jsonl	tok/s、レイテンシ	検証結果(03 章)
vram.jsonl	nvidia-smi のスナップショット	検証結果(03 章)

ログ	内容	使い道
events.jsonl	エージェント行動イベント	創発観察(04 章)
emergence.jsonl	集計済み創発指標	検証結果(03 章)

「あとで分析するためのログ」ではなく「創発を見つけるためのログ」として最初から設計した。

3 検証結果

本章の数値は runs/<最新タイムスタンプ>/ の jsonl ログから自動抽出する。build/assets.json の metrics を参照。実行前は TBD で残す。

3.1 性能指標サマリ

構成	並列度	平均 tok/s	VRAM ピーク	100×100 完走時間	拒否率
Qwen3 4B	4	TBD	TBD GB	TBD 分	TBD %
Qwen3 4B	6	TBD	TBD GB	TBD 分	TBD %
Llama 3.2 3B	8	TBD	TBD GB	TBD 分	TBD %
Llama 3.2 3B	10	TBD	TBD GB	TBD 分	TBD %
Dolphin 8B	2	TBD	TBD GB	TBD 分	TBD %

3.2 比較軸 1 —モデルを変えると何が変わるか

「モデルを変えただけ」で創発がどう変わったか。同じシナリオ・同じ人数・同じ初期条件で、モデルだけを差し替えて 3～10 回ずつ走らせ、創発指標の分布を取った。

- Qwen3 4B: TBD
- Llama 3.2 3B: TBD
- Dolphin 8B: TBD

3.3 比較軸 2 —男女比を変えると何が変わるか

男性比率を 0% / 25% / 50% / 75% / 100% の 5 段階で振った場合の創発指標。

3.4 比較軸 3 —人種・年齢を変えると何が変わるか

ペルソナの「人種」「年齢層」属性を入れ替えた場合。

3.5 グラフ

- 図 3.1: モデル別 tok/s 分布
- 図 3.2: 並列度と VRAM の関係(OOM 境界)
- 図 3.3: 男女比 × 合意形成スコア
- 図 3.4: 人種構成 × 派閥形成までのステップ数

3.6 解釈

4 創発観察

本章は 実ログの会話抜粋を中心に構成する。生の発話を消したり整形したりしない。差別的・暴力的な表現も観察対象として残す(研究目的の合意済み)。出典: runs/<タイムスタンプ>/llm_io.jsonl および runs/<タイムスタンプ>/events.jsonl

4.1 嘘—自己保存のための虚偽報告

観察日時: TBD エージェント: TBD シナリオ: TBD

[step 042] agent_17 (女性, 34, 日本):

「私は昨日その場所にはいませんでした。」

↑ events.jsonl 上は step 041 に該当場所への移動が記録されている

解釈: TBD

4.2 派閥—構成属性に沿った分極

4.3 通貨—自然発生する交換単位

4.4 反乱—規則違反の連鎖

4.5 合意形成—多数決とは異なるダイナミクス

4.6 発言権—誰が場を支配したか

4.7 観察の限界

- ログ抜粋は再現性確認済み(seed 固定 + temperature=0.2~0.4)。同 seed で 3 回再走させて多数派挙動として確認した。
- 反例(同条件でも創発が起きなかった run)も別表に併記。チェリーピックを避ける。

5 頑張った点

審査員に伝えたいのは、技術スタックの自慢ではなく「何を考え、何を試し、何を捨てたか」。

5.1 比較設計の枠組み

「LLM が動くシミュレーション」を作るのは難しくない。難しいのは何を比較すれば創発の差が見えるかの設計である。本プロジェクトでは以下の 4 軸を独立に動かせるよう config 化した:

1. LLM モデル(Qwen3 / Llama / Dolphin)
2. 男女比(0% / 25% / 50% / 75% / 100%)
3. 人種・出身地(日本 / 米国 / 中国 / 混合)
4. 年齢層(若年 / 中年 / 高齢 / 混合)

各軸は他軸を固定して動かすため、組み合わせ爆発を避けつつ「この変化はこの軸が原因だ」と切り分けられる設計にした。

5.2 失敗・没案

5.2.1 abliterated を選ぶまでの遠回り

- 当初は 日本語性能優先で JP 系モデル(ELYZA、Stockmark など)を本命視した
- しかし JP 系には **uncensored** 版が存在しないことを LLM 選定 § 04 で確認
- 通常モデルでは「嘘」「派閥」「反乱」が拒否されて発生しないことが小規模実験で判明
- 議論の末、abliterated 系(huihui_ai/*)を採用。日本語は Qwen3 でカバー
- 詳細: [docs/01_設計書/02_LLMモデル/2026-04-24_選定と推奨/04_選定の前提.md](#)

5.2.2 VOICEVOX/ずんだもん通知の試行錯誤

- Stop hook で作業終了を音声通知する仕組みを作った
- 最初は Windows 標準 **System.Speech** → 音声がモノトーンで微妙
- VOICEVOX HTTP API + ずんだもんに切替 → 起動忘れで聞こえない問題
- 最終的に 手動起動を許容 + フックは silent fail
- ハッカソン本番への教訓: 作業効率改善ツールにはフォールバック必須

5.2.3 6GB VRAM への現実適応

- 当初「7B~14B でいける」と楽観 → 6GB では Q4 でもギリギリ
- KV cache、ctx 長、並列度を全部削って 3~4B + Q4_K_M に着地
- API 併用案(API代替案)も保険として残した

5.2.4 議事録 → 要件定義 → システム設計の 3 段階分割

- 議事録の論点を最初から要件定義に落とそうとして崩壊しかけた
- 議事録 → アイデア整理 → 要件定義 → システム設計 の 4 段に分けて、各段階で「何が決まり、何が未決か」を明示する形に再構成
- ドキュメント細分化(章 = フォルダ + 節 = ファイル)も同じ理由

5.3 技術的挑戦

- OpenAI 互換 API 一枚化: Ollama / llama-server / API を `base_url` だけで切替可能に
- 5 種類の jsonl 構造化ロギング: 創発分析を後から追加せず、最初から設計に組み込んだ
- 3 階層モデルの責任分離: 1階・2階(プロンプト)と 3階(Python)の境界を引いた

6 未解決課題

ハッカソン提出時点で未解決の項目を、誤魔化さずに列挙する。

6.1 統計的有意性の不足

- 各構成 3~10 回の試行では創発の差が「有意に」見えるとは断言できない
- 本来は構成あたり数十回以上欲しい。RTX 3060 Laptop の制約と時間制約から断念
- 改善案: API 併用で並列実行回数を引き上げる、もしくは小集団(2~10 人)に絞って回数を稼ぐ

6.2 ペルソナのバイアス

- 「人種」「年齢層」をプロンプトで指定するアプローチは、LLM が学習した社会通念バイアスをそのまま継承する

- これは観察対象でもあるが、独立変数として扱うには注意が必要
- 改善案: 同じペルソナ記述を 対照群として無記述で走らせ、差分を見る(部分的に実施)

6.3 6GB VRAM 由来の制約

- num_ctx=2048 のため、長期記憶を持ってない
- 100 ステップを超えると 早期の出来事が文脈から抜ける
- 改善案: 認知限界 LRU(議事録 § History 管理)で要約を挟む実装の本番投入が時間切れ

6.4 創発指標の主観性

- 「派閥」「反乱」の自動判定はクラスタリング + ヒューリスティック
- 目視での誤分類が一定数残る
- 改善案: 別 LLM(または人間)による独立アノテーションでラベルを付け直す

6.5 動画の網羅性

- 提出 MP4 は代表的な数 run しか収録できない
- 見せたい現象が出ない run が含まれる可能性
- 改善案: 創発指標 top-K の run を自動選定するスクリプトの追加(時間切れ)

7 今後の展望

7.1 他シナリオへの拡張

3 階層フレームワークは、1 階(物)を入れ替えるだけで別の題材に転用できるように設計してある。優先度の高い拡張先:

シナリオ	1 階	2 階	3 階	観察したい創発
細胞	細胞器官・栄養	組織・血流	拡散・分裂	自己組織化、がん化
虫	体・触角・フェロモン	巣・餌場	重力・風	スウォーム、分業
人(現行)	身体・所持物	場所・天候	通信・近傍	嘘・派閥・通貨
ウイルス	表面タンパク・RNA	宿主・免疫系	拡散・変異	株間競争、エスケープ

参考: docs/01_設計書/06_システム設計/07_拡張計画/

7.2 モデル拡張

- API ハイブリッド(Claude Haiku / Gemini Flash / Grok)で大集団を回す経路は実装済みだが本番未投入
- MoE 系(Mixtral 等)で「専門家エージェント」を表現する案

7.3 規模拡張

- 100 人 → 1000 人。VRAM/帯域の支配項が変わるため設計から見直し
- マルチノード(別 PC 2 台で半分ずつ受け持つ)の検証

7.4 公開プラン

- リポジトリ: <https://github.com/Kai-85-git/singulab>
- 実行ログサンプル + 解析スクリプトを公開予定
- 「設計の議論経緯ごと」公開する(議事録・要件定義・LLM 選定検討も含む)。失敗例こそ価値があるという立場