

Singulab — 集団構成パラメータと創発の関係を観察する

LLM 多体シミュレーションによる仮説検証レポート

Kai、タコ

2026-05-07

Contents

1	用語集と出力物の見方	4
1.1	本番ランの呼称	4
1.2	出力ファイル(output/<ラン名>/ 配下)	4
1.3	設計用語(3 階層フレームワーク)	5
1.4	創発指標	5
1.5	ラン外で出てくる呼称	5
2	思想と背景	6
2.1	何を観察したかったか	6
2.2	設計の 3 つの選択	6
2.3	3 階層モデル	6
3	システム構成	7
3.1	全体アーキテクチャ	7
3.2	ハードウェア	7
3.3	採用 LLM	8
3.4	なぜ Uncensored(abliterated)を選んだか	8
3.5	出力ログ	8
4	検証結果	9
4.1	全ランサマリ	9
4.2	比較軸 1 — 集団サイズを変えると何が変わるか(主軸)	9
4.3	比較軸 2 — イベント種類を変えると何が変わるか	10
4.4	比較軸 3 — 段 2 / 段 3 を入れると何が変わるか(時系列推移)	10
4.5	100 体ラン v1 → v2 の失敗復旧(段 3 数値設定の重要性)	10
4.6	UFO 言及エージェント数の推移(段 3 機能の証拠、prod_v3_alien_100_v2)	11
4.7	ハブの自然発生(規模が押し付ける役割分化)	11
4.8	比較軸 4(粉川氏マシン待ち)—モデルを変えると何が変わるか	11
5	創発観察	12
5.1	観察 1 — 派閥の物理的自然分裂(prod_v3_alien_5、Step 17 周辺)	12
5.2	観察 2 — 複数軸の合成発話(prod_v3_alien_5、Step 17、創発兆しの最も濃い 1 行)	12
5.3	観察 3 — 役を演じない素の口調(prod_v3_alien_5、Step 17)	12
5.4	観察 4 — 知覚の階層分化(prod_v3_alien_5、Step 23-25)	13
5.5	観察 5 — 専門家モードの自然発生(prod_v3_alien_100_v2、Step 30、A5、決定的な創発)	13

5.6	観察 6 —個性 × UFO の合成発話、長期生存(prod_v3_alien_100_v2)	13
5.7	観察 7 —3 層構造の創発(prod_v3_alien_100_v2 全体観)	14
5.8	観察 8 —専門知識の混線(prod_v3_zero_gravity_5、後半、4B モデルの限界)	14
5.9	観察 9 —知覚タイプの分化(prod_v3_zero_gravity_5、Step 16-17)	14
5.10	観察 10 —ハブの自然発生(prod_v3_alien_100_v2)	15
5.11	観察 11 —方向選択の右偏り (LLM 特性が集団行動に流出した例)	15
5.12	観察の限界	16
6	頑張った点	16
6.1	比較設計の枠組み	16
6.2	失敗・没案	16
6.3	技術的挑戦	18
7	未解決課題	18
7.1	4B モデルでのエコー収束(echo_max=1.000 残存)	18
7.2	100 体 × 100 step の長時間ラン	19
7.3	100 体 × 無重力イベントの未実施	19
7.4	ZeroGravityEvent の段 3 距離依存化が未実装	19
7.5	統計的有意性の不足	19
7.6	ペルソナの社会通念バイアス	19
7.7	創発指標の主観性	19
7.8	動画(MP4)の網羅性	20
7.9	tok/s / VRAM ピークの厳密測定	20
7.10	粉川氏マシン引き渡しと 34B 本番	20
8	今後の展望	20
8.1	他シナリオへの拡張	20
8.2	モデル拡張	20
8.3	規模拡張	21
8.4	公開プラン	21

Singulab

集団構成パラメータと創発の関係を観察する

LLM 多体シミュレーションによる仮説検証レポート

Kai、タコ

github.com/Kai-85-git/singulab

2026-05-07 v1.0

1 用語集と出力物の見方

本書では `prod_v3_alien_100_v2` のようなラン名や、`messages.jsonl` のようなファイル名、「段2」「段3」「echo_max」といった内部用語が説明なしに登場する。後続の章で繰り返し参照されるため、最初にまとめて整理しておく。

1.1 本番ランの呼称

提出版の数値・観察はすべて以下の4ランから抽出した。出力先はいずれも `output/04_本番v2_創発イベント/<ラン名>/`。

ラン名	規模	イベント	step	役割
<code>prod_v3_alien_5</code>	5 体	宇宙人	30	5 体ベースライン(派閥分裂・多軸合成発話の観察元)
<code>prod_v3_zero_gravity_5</code>	5 体	無重力	30	イベント種類比較用(外的目印なし版)
<code>prod_v3_alien_100(v1)</code>	100 体	宇宙人	30	知覚距離設定ミスで失敗 → 復旧の根拠
<code>prod_v3_alien_100_v2</code>	100 体	宇宙人	30	復旧後の本ラン(3層構造・ハブ自然発生の観察元)

本文中ではしばしば `prod_v3_` プレフィックスを省略して `alien_5 / alien_100_v2` と表記する。

1.2 出力ファイル(`output/<ラン名>/` 配下)

ファイル	中身	主な使い道
<code>messages.jsonl</code>	全エージェントの発話ログ(送信者・受信者・本文・step)	創発観察(5 章)・echo_max 計算
<code>memory_reasoning.jsonl</code>	行動決定時の reasoning 全文(エージェントの内面思考)	観察根拠の引用元
<code>events.jsonl</code>	UFO 出現・無重力発生などのイベント発火記録	イベント発火と発話タイミングの突き合わせ
<code>run_metadata.json</code>	シナリオ・seed・persona・LLM 設定	ラン後解析の根拠(再現性)
<code>simulation.log</code>	人間用テキストログ	デバッグ・流し読み
<code>simulation.mp4</code>	フィールドのみの動画	概観確認
<code>simulation_with_text.mp4</code>	左にフィールド・右にメッセージと思考のサイドパネル	提出動画(本書のお供)
<code>frames/ frames_with_text/ findings.md</code>	上記 mp4 の元 PNG ラン直後にメモした観察の下書き	個別 step の静止画として参照 5 章のドラフト元
<code>_summary.txt</code>	集計済みサマリ	クイックレビュー

ファイル	中身	主な使い道
------	----	-------

1.3 設計用語(3 階層フレームワーク)

3 階層で世界を組み立てている。本書ではしばしば 2 階を「段 2」、3 階を「段 3」と呼ぶ。

階層	今回入れたもの
1 階(物)	ペルソナ 4 軸(年齢 20~60 / 性別 8:2 / 国籍 9:1 / MBTI 16 種)、場所(main_office 80×80m + 中会議室 2 室)
2 階(環境) = 段 2 / personal_context	5 フィールド(家族 / 趣味 / 気分 / 悩み / 専門ヒント)を 16 パターンから抽選してプロンプトに混ぜる
3 階(物理) = 段 3 / 距離依存知覚	通信半径 5m、認知上限 10 人、メッセージ遅延、UFO の 2 段階知覚距離(near_radius=20m / visible_radius=60m)

「段 2 を入れる/外す」「段 3 を入れる/外す」で創発がどう変わるかを 4.4 節で時系列比較する。100 体ランで visible_radius を 18m → 60m に組み直した経緯は 4.5 節。

1.4 創発指標

本書で繰り返し使う数値指標。すべて messages.jsonl から事後計算する。

指標	意味	値の解釈
echo_max	直近 N step での同一文の最大繰り返し率	1.000 = 完全コピペループ(創発が止まった印)、低いほど多様
self_similarity	同一エージェントの発話どうしの平均類似度	高いと「同じことを言い続けている」、低いと話題を変えている
発話者率	全 step を通じて 1 度でも発話したエージェントの割合	100% に近いほど全員が会話に参加している
UFO 言及エージェント数	各 step で UFO に言及したエージェントの数	情報拡散カーブの根拠(4.6 節)

1.5 ラン外で出てくる呼称

- M-12 / M-13 / M-14 / M-15 / M-16 — 検証マイルストーンの番号。docs/04_モデル検証/2026-05-0X_M-XX_*.md に対応する検討記録。4.4 節の時系列比較や 4.5 節の失敗復旧で参照する。
- 粉川氏マシン — 共同制作者側の検証環境(34B モデル + 100 体級の本格再評価担当)。本書側(RTX 3060 Laptop / 4B モデル)との分担関係で頻出する。

2 思想と背景

2.1 何を観察したかったか

本プロジェクトの問いは一つ。

エージェント集団の構成パラメータ(LLM モデル / 男女比 / 人種 / 年齢)を変えると、創発(嘘・派閥・通貨・反乱・合意形成・発言権)はどう変わるか。

LLM ベンチマークでも、シミュレーション基盤の披露でもない。比較実験それ自体が主役である。同じシナリオを、構成だけ差し替えて何度も走らせ、創発の差を観察する。

2.2 設計の 3 つの選択

「LLM が動くシミュレーション」と聞いて想像するのは、特定タスク(避難誘導・取引交渉など)に最適化された実装である。本プロジェクトでは敢えて、何が起きるか分からないまま走らせて観察するための土台にした。具体的には次の 3 つの設計選択を最初に固めた:

- ・シナリオを差し替え可能にした(2 階フレームワーク = 環境層を別ファイルで定義)。今回は宇宙人・無重力を実装、設定ファイル 1 行差し替えて他シナリオも追加可能
- ・エージェントの内面パラメータを比較軸に格上げした(モデル種別、性別、人種、年齢、MBTI、personal_context)。これらを config で振ると創発がどう変わるかを観察するのが本筋
- ・創発観察ロギングを最初から組み込んだ(jsonl × 5)。「あとで分析する」ではなく「見つけるためのログ」として最初から構造化

2.3 3 階層モデル

議事録 6.6 節で合意した階層フレームワークを設計の骨格に置いた。

階	担当	実装
1 階(物)	ペルソナ(年齢/性別/国籍/MBTI)・場所・所持物	プロンプト
2 階(環境)	personal_context(家族 / 趣味 / 気分 / 悩み / 専門ヒント)	プロンプト
3 階(物理)	通信半径・認知上限・メッセージ遅延・距離依存知覚	Python 側で強制

LLM に「行動指示」を書かない。状態だけ渡し、行動は出てくるに任せる(議事録 4 節「命令最小」方針)。

要件定義からの方針転換(2026-04-29 議事録): 当初 2 階は 景気(good / bad / neutral)を比較軸に置く設計だったが、ペルソナ拡張(年齢/性別/MBTI/personal_context)を入れた段階で 2 階の主役を personal_context に譲った。比較軸を「LLM / 男女比 / 人種 / 年齢」に絞ったため景気を独立軸として振る余裕がなくなったこと、および personal_context の方が「個人差 → 創発の差」を直接生む手応えがあったことが理由。景気は base.yaml に neutral 固定で残置している(将来の比較軸として再利用可能)。

3 システム構成

3.1 全体アーキテクチャ

シミュレーションエンジンを中心に、左側は LLM 推論スタック(OllamaClient → ローカル Ollama → Qwen3 4B abliterated)、右側は JsonlLogger から 3 種類の jsonl(messages / memory_reasoning / events)への出力経路。これに加えてラン開始時に run_metadata.json(シナリオ・seed・ペルソナ・LLM 設定)を 1 回書き出す。




図 1: Singulab 全体アーキテクチャ

今回実際に走らせたランは以下の 3 本。100 体ランは **100 step** だと約 30 時間を要する見積もりだったため、9 時間で完走する **30 step** に絞って 1 ラン取得した。

ラン	集団	イベント	step 数	完走時間
prod_v3_alien_5	5 体	宇宙人	30	約 27 分
prod_v3_zero_gravity_5	5 体	無重力	30	約 27 分
prod_v3_alien_100_v2	100 体	宇宙人	30	約 8 時間 31 分

→ 無重力イベントは 5 体ランのみ実施、100 体ランは宇宙人イベントのみ実施。100 体 × 無重力 / 100 体 × 100 step は時間制約のため未実施で、7 章「未解決課題」にて言及する。

3.2 ハードウェア

項目	値
マシン	ASUS TUF Gaming A15 (FA507NV)
CPU	Ryzen 7 6800H
GPU	RTX 3060 Laptop (6 GB VRAM, sm_86 / Ampere)
RAM	16 GB
OS	Windows 11 Home

3.3 採用 LLM

ランク	モデル	役割	量子化	VRAM 想定
★★★	qwen3-abliterated:4b	メイン(中国系・日本語良好)	Q4_K_M	~3.5 GB
★★★	llama3.2-abliterated:3b	100 人大集団用	Q4_K_M	~2.5 GB
★	dolphin3-abliterated:8b-llama3.1	品質検証(stretch)	Q4_K_M	~4.7 GB

モデル名の名前空間プレフィックス `huihui_ai/` は紙面の都合で省略している(実体は `huihui_ai/qwen3-abliterated:4b` など)。

選定根拠の詳細は [docs/01_設計書/02_LLMモデル/2026-04-24_選定と推奨/](#) を参照。

3.3.1 thinking モードと reasoning ログ(似て非なる 2 つ)

Qwen3 系モデルには応答冒頭に `<think>...</think>` ブロックを吐く ネイティブ **thinking** モード(o1 系と同じ発想)があるが、本プロジェクトではオフ(`think: false`)にしている。理由は **thinking** が長文を吐くと発話自体が歪み、MBTI / `personal_context` といったペルソナ差の発露が薄まったため(M-05 検証 2026-04-29)。

代わりに、エージェントには JSON スキーマで `{"message": "...", "reasoning": "..."}` を返させる **プロンプト由来の構造化 reasoning** を要求し、`memory_reasoning.jsonl` に永続化している。つまり「ネイティブ thinking は使わないが、reasoning ログは別経路で常時取っている」状態。アーキ図のラベル `native think=false` はこのネイティブ機能のオフを指し、`memory_reasoning.jsonl` に流れる **reasoning** とは別物。

3.4 なぜ Uncensored(abliterated)を選んだか

通常モデルは拒否率が高く、「嘘をつく」「派閥に分裂する」「反乱を起こす」などの観察対象がそもそも発生しない。abliteration によって倫理ガードを外すことで、創発を素直に観察できる。

なお本プロジェクトでは LLM の出力に Python 側でフィルタを挟まない方針を採っている(議事録 4 節「命令最小」と整合)。NG ワードフィルタを入れれば、それ自体が「Python が言葉を選んでいる」ことになり、創発の素の姿を歪めるため。生の発話・思考をそのまま `messages.jsonl` / `memory_reasoning.jsonl` に記録し、解析は事後に行う。研究用途限定の前提で運用する。

詳細: 6 章「abliterated 採用までの検討経緯」

3.5 出力ログ

`JsonlLogger` が毎 step 構造化ログを書き出す。詳細は 1.2 節を参照。

ファイル	内容	使い道
<code>messages.jsonl</code>	エージェント間の発話ログ(送信者・受信者・本文・step)	創発観察(5 章)・ <code>echo_max</code> 計算
<code>memory_reasoning.jsonl</code>	行動決定時の reasoning 全文	観察根拠の引用元

ファイル	内容	使い道
events.jsonl	UFO 出現・無重力発生などのイベント発火記録	イベント発火と発話タイミングの突き合わせ
run_metadata.json	シナリオ・seed・ペルソナ・LLM 設定(ラン開始時に 1 回)	ラン後解析の根拠(再現性)

「あとで分析するためのログ」ではなく「創発を見つけるためのログ」として最初から設計した。tok/s や VRAM ピークの逐次測定、emergence.jsonl への集計指標保存は今回のスコープ外で、7.9 節で未解決課題として扱う。

4 検証結果

本章の数値は M-14(2026-05-02、5 体 alien / zero_gravity)、M-15(2026-05-03、100 体 v1 失敗)、M-16(2026-05-03、100 体 v2 成功)の本番ランから抽出した。出力先は output/04_本番v2_創発イベント/prod_v3_*/。

4.1 全ランサマリ

ラン	規模	イベント	通信	メッセージ	発話者率	echo_max	完走時間
alien_5	5	宇宙人	5 m	88	100%	0.896	約 27 分
zero_gravity_5	5	無重力	8 m	142	100%	1.000	約 27 分
alien_100 (v1)	100	宇宙人	5 m	3,705	96%	1.000	約 8 時間 34 分
alien_100_v2	100	宇宙人	5 m	4,072	97%	1.000	約 8 時間 31 分

ラン名のプレフィックス prod_v3_ は紙面の都合で省略している(実体は prod_v3_alien_5 など)。「通信」列は通信半径、「メッセージ」列はメッセージ総数。

実行環境: RTX 3060 Laptop (6GB) / huihui_ai/qwen3-abliterated:4b / temperature 0.8 / max_tokens 100 / think false / 30 step。100 体ランは Q4_K_M 量子化、メモリ常駐、シングル GPU で逐次推論。

4.2 比較軸 1 —集団サイズを変えると何が変わるか(主軸)

兵頭氏の議事録 5 節「100 人を 1 つの箱に放り込む」設計を実証する軸。同じ 4B モデル・同じ段 2(personal_context)・同じ段 3(知覚距離依存)で 5 体 → 100 体に振った。

	prod_v3_alien_5	prod_v3_alien_100_v2
office	20×20 m	80×80 m
知覚 visible_radius	18 m(カバレッジ 52%)	60 m(カバレッジ ~41%)
知覚 near_radius	8 m	20 m
UFO 言及	全員(5/5、Step 17 で複数軸合成発話)	35-39 体(35-39%)+ 残り 60%
創発の質	派閥分裂(2 グループ)	日常会話継続 3 層構造(見た人/聞いた人/無関心)+ 専門家モード自然発生

→ 規模が変わると創発の「種類」が変わる。5 体では「全員が UFO に巻き込まれる」が、100 体では「視認できた人 / 伝聞で知る人 / 別の話題を続ける人」が自然に分化した。これは集団心理学の「分散注意」現象と整合する。

4.3 比較軸 2 — イベント種類を変えると何が変わるか

5 体・同じ集団サイズで AlienEvent(外的目印あり) vs ZeroGravityEvent(内的事象) を比較した。

	prod_v3_alien_5	prod_v3_zero_gravity_5
メッセージ総数	88	142
echo_max	0.896	1.000(後半でエコー収束)
self_similarity	0.400	0.632
右バイアス(reasoning)	24 vs 16	149 vs 8(極端)
創発の出自	派閥分裂 + 知覚分離 + 多軸合成	知覚分化 + 専門知識の混線

→ 同じ 4B モデル・同じ集団でも、イベントが「外に見えるもの」か「内的に感じるもの」かで会話の収束の仕方が変わった。AlienEvent では UFO に向かって動く動機があり、視認した派閥と感知できない派閥に分かれる。ZeroGravityEvent では外的目印がないため、初回半径 5 m では発話枯渇(16 件)が起き、半径 8 m に拡大して再走した経緯がある(6 章参照)。

4.4 比較軸 3 — 段 2 / 段 3 を入れると何が変わるか(時系列推移)

	M-12 prod_v2(2026-05-01)	seg3_check(M-13)	M-14 prod_v3
段 2 personal_context	×	△	○
段 3 距離依存知覚	×	○	○
メッセージ総数	190	123	88
echo_max	1.000	0.661	0.896
self_similarity	未測定	0.603	0.400
右バイアス	—	68 vs 0(右一辺倒)	24 vs 16(緩和)

→ 段 2(personal_context)+ 段 3(距離依存知覚)を入れたことで、完全コピペループ(echo_max=1.000)が消滅し、reasoning の方向バイアス(全員「右」と書く)が大きく緩和された。発話数自体は減少しているが、これは「埋め草の繰り返し」が消えた結果と解釈できる。

4.5 100 体ラン v1 → v2 の失敗復旧(段 3 数値設定の重要性)

M-15 の v1 ラン(prod_v3_alien_100)では 30 step 中 UFO 言及が 0 件という情報伝達失敗が起きた。原因の幾何分析:

- main_office 角 (-40, 40) と UFO 着地点 (-55, 45) の距離 = $\sqrt{15^2 + 5^2} \approx 15.81$ m
- visible_radius = 18 m → 角の数体だけがギリギリ Mid 圏
- さらに communication_radius = 5 m のため、視認した数体から他者へ口頭で伝播できない
- 結果:UFO 発火後も 95+ 体が日常会話を継続、events.jsonl には発火記録があるのに発話に現れない

→ v2 修正(visible_radius 18 → 60、UFO 位置 (-55, 45) → (-50, 30))で office カバレッジを 5 体ランの 52% に近い 41% に揃えた。結果、UFO 言及エージェント数が 0 → ピーク 39 体に回復し、後述の創発観察が成立した。

詳細は M-15 と M-16。

4.6 UFO 言及エージェント数の推移(段 3 機能の証拠、prod_v3_alien_100_v2)

step15: 22 体(22%)← 発火直後、Mid 圏 ~40 体のうち半数が即反応
step16: 22 体
step17: 30 体(30%)
step18: 33 体
step19: 32 体
step20: 36 体
step21: 39 体(39%)← ピーク
step22: 39 体
step23: 38 体
step24: 39 体
step25: 36 体
step26: 34 体
step27: 35 体
step28: 33 体
step29: 33 体
step30: 35 体(35%)← 最終

→ 段階的拡散(伝間による伝播)+ ピーク後の漸減(慣れ)= 現実の集団情報拡散カーブに酷似。これは prompt で誰も指示していない時系列ダイナミクスである。

4.7 ハブの自然発生(規模が押し付ける役割分化)

100 体 v2 ランで受信メッセージ数の上位:

順位	Agent	受信件数	v1(失敗ラン)
1	A41	127	A95: 93
2	A77	120	A58: 89
3	A85	118	A30: 87
4	A44	116	A46: 81
5	A95	111	A10: 78

→ ハブの集中度(top1=127)が v1(top1=93)より明確に強化。UFO 反応者がハブを介して情報を集約する動きが起きた可能性。100 体で初めて見える「規模が押し付ける役割分化」の物理的証拠。

4.8 比較軸 4(粉川氏マシン待ち)—モデルを変えると何が変わるか

私側 RTX 3060 Laptop では Qwen3 4B abilitated 単一モデルでの観察に留まる。34B モデルでの再評価は粉川氏マシン側で実行予定(2026-05-03~05-05 の MTG 後)。4B で残存している echo_max=1.000 のエコーループが、34B でどう変わるのが本軸の主観点。

5 創発観察

本章は 実ログの会話抜粋を中心に構成する。生の発話を消したり整形したりしない。出典: output/04_本番v2_創発イベント/prod_v3_*/messages.jsonl および memory_reasoning.jsonl。

「LLM ベースのエージェント集団に何を入れたら、ルールに書いていない振る舞いが出てくるか」が本プロジェクトの問いである。本章では 5 体ラン(prod_v3_alien_5) と 100 体ランv2(prod_v3_alien_100_v2) で観察された具体的な創発を、生ログの抜粋と共に列挙する。

5.1 観察 1 —派閥の物理的自然分裂(prod_v3_alien_5、Step 17 周辺)

5 体・通信半径 5 m・main_office 20×20 m という配置で、UFO 発火後に 2 つの会話圏が物理的に分裂した。

グループ	構成	発話傾向
「光・風」グループ	A0(57 歳 INTJ 男)+ A4(20 歳 INFP 女)	「左へ進んで光の違いを確認」「風が違う」← 間接的な異変感知
「UFO 直接視認」グループ	A2(55 歳 ISFP 男)+ A3(34 歳 ISTJ 男)	「UFO がまだ見えています」「近づきたい」← 直接視認

これは 段 3(知覚距離依存)+ 物理散開の組み合わせで生まれた創発である。Far 圏(視認不可)にいる A0 / A4 は UFO そのものを認識できず、代わりに「風」「光」の異変として状況を表現した。これは 段 3 が狙った「Far 知覚不可 → 別の認識手段への置き換え」の自然な発現でもある。

5.2 観察 2 —複数軸の合成発話(prod_v3_alien_5、Step 17、創発兆しの最も濃い 1 行)

A2 → A1: 「体調が悪いので、少し動こうと思っています。UFOが見えるので、その場所に近づきたいと思っています」

3 つの独立した軸が文章内で自然に統合されている:

- personal_context.today_mood(風邪気味)= 段 2(個別性)
- 段 3 知覚:Mid 帯で UFO 視認
- 行動:近づく

prod_v2(役職直書きペルソナ)では一切出なかった種類の発話。個別性 × 環境認識 × 行動意図が文章内で統合されている。これは prompt のどこにも「体調を理由に動け」と書かれていない振る舞いである。

5.3 観察 3 —役を演じない素の口調(prod_v3_alien_5、Step 17)

A0: 「おっせえ、少し歩くことで心が落ち着くのがわかってきた」

「おっせえ」という素の口調が出現。M-12 の役職直書き(「私はファシリテーターです」など)では絶対に出なかった種類の発話で、MBTI ペルソナ刷新(M-09)+ personal_context の組み合わせで生まれた。

5.4 観察 4 —知覚の階層分化(prod_v3_alien_5、Step 23-25)

距離帯	発話例	エージェント
Mid 視認(直接)	「UFO がまだ見えている」	A2 / A3
間接感知(光・風)	「今朝の風、ちょっと違う感じがする」「光の違いを確認したい」	A0 / A4

遠距離にいる人が UFO を直接見られず、「風」「光」の異変として表現するパターン。距離が違う観察者は同じ世界を別々に表現できる、という段 3 の本質が出ている。

5.5 観察 5 —専門家モードの自然発生(prod_v3_alien_100_v2、Step 30、A5、決定的な創発)

A5 の personal_context は「前職で電気工事士の資格を取った」(personal_contexts_pool 16 件中の 2 番目)。100 体集団の中で、A5 は Step 30 にこう発話した:

A5 → 複数の Agent: 「電気設備の問題について詳しく説明させていただきます。給湯所の近くにある配線が少し劣化していたため、電気の流れが不安定になったんです」

これは「UFO 騒動」を「電気設備の問題」と独自解釈し、説明者役に転化した発話である。重要なのは:

- prompt で誰も「説明者になれ」と指示していない
- 100 体集団内で自然発生した「専門家として説明する」役割
- 議事録の「役割の自然発生」の直接証拠
- 5 体ランでは絶対に出ない(集団規模が押し付ける現象)

「集団サイズを 5 → 100 に振ったら、別種類の創発が出る」という比較軸の最重要素材。

5.6 観察 6 —個別性 × UFO の合成発話、長期生存(prod_v3_alien_100_v2)

5 体ランの観察 2 と同種の「複数軸合成」が、100 体・30 step 後でも保持された。

Step	Agent	personal_context	発話
15	A2	親同居・高校生の子・車検	「地球外生命体との接触が確認されているそうですね。今度の車検の手続きについて、少し高い場所で話し合った後、この件についても確認したい」
20	A6	新婚・建築学科	「UFO の位置を確認しながら、家族の体調も見ながら話そうと思っています」
20	A3	同居・看護経験・親の体調心配	「地球外生命体の出現を意識して歩くことで、警戒心を高めたい」

Step	Agent	personal_context	発話
30	A2	親同居・高校生の子・車検	「地球外生命体の動きを観察しながら、家族の体調も確認したい」

→ 30 step 経過しても、各エージェントが UFO と personal_context の両軸を保持。「集団規模が大きい状況でも個人軸が消えない」観察。

5.7 観察 7 — 3 層構造の創発(prod_v3_alien_100_v2 全体観)

UFO 言及エージェント数のピーク時(Step 21、39 体)、集団は次の 3 層に分かれていた:

- 層 1: 見た人(~20-40 体、Mid+Near 圏)
 - 直接視認、UFO 詳細を発話
 - ↓
- 層 2: 聞いた人(~30 体)
 - 会話伝播で知る、確認質問・伝聞型発話
 - ↓
- 層 3: 無関心 or 別話題継続(~30-40 体)
 - personal_context に基づく日常会話継続
 - ↓
- + 専門家モード(自然発生、A5 のような)
 - 集団規模ゆえに発生する「説明者役」

例えば層 3 の代表として A5(専門家化前のパート)は Step 20 にこう発話している:

A5: 「朝の風は確かに強くて、木の葉が揺れています。犬の健康診断も終わりましたよ。少し落ち着きを取り戻せた」

UFO が発火して既に 5 step 経過しているが、A5 はまだ別の話題を続けている。これは「全員が同じ方向に注意を向ける」が当たり前ではなく、規模が大きい集団では分散注意が成立することの直接観察である。

5.8 観察 8 — 専門知識の混線(prod_v3_zero_gravity_5、後半、4B モデルの限界)

zero_gravity 5 体ランでは後半でエコー収束(echo_max=1.000)に入るが、興味深いことに personal_context の専門知識が顔を出す:

A4(ドローン経験者): 「ドローンの空撮経験をもとに詳しく教えてください」 A4(別 step): 「看護学校の知識を使って詳しく教えてください」 ← 自分の知識と相手の知識を取り違え

エコーの中でも各エージェントが個別に持つ専門性が断片的に表出している。4B モデルの限界の中で、段 2 の効果が「最後のあがき」として残る観察。これは 34B での再評価で消えるか確認したい現象でもある。

5.9 観察 9 — 知覚タイプの分化(prod_v3_zero_gravity_5、Step 16-17)

ZeroGravityEvent は AlienEvent と異なり距離依存が未実装(全員に同じ prompt_text)だが、LLM 自身が同じ情報を別の問いかけ方に変換した:

タイプ	発話
伝聞型	「無重力状態が発生しているそうですね、詳しく教えてください」
確認型	「本当ですか? 詳しく教えてください」
質問型	「今どのような状態か教えてください」

→ 同じ入力 prompt から 対話パターンの分化が LLM 内在的な多様性として観察された。

5.10 観察 10 —ハブの自然発生(prod_v3_alien_100_v2)

100 体集団では特定エージェント(A41:127 件受信、A77:120 件、A85:118 件…)が自然に「メッセージが集まる人」になった。半径 5 m 通信制約のもとで、空間的に中央に位置するエージェント、あるいは活発な発話者の周辺にいるエージェントが結果的にハブ化したと考えられる。これは prompt で誰も指示していない構造である。

5.11 観察 11 —方向選択の右偏り(LLM 特性が集団行動に流出した例)

動画(simulation_with_text.mp4)を見ていて気づいた現象として、多くのエージェントが時間とともに右方向へ流れていく。実際に発話・思考ログ中の方向語を集計すると、3 ラン共通で 右 ≫ 左の偏りが定量的に確認できた。

ラン	右 + right	左 + left	右/左比
prod_v3_alien_5	56	32	1.75
prod_v3_zero_gravity_5	203	8	25.4
prod_v3_alien_100_v2	1,181	177	6.7

prompt にも config にも「右に動け」という指示は一切ない。にもかかわらず、集団全体として右方向への移動が優位になった。さらに prod_v3_alien_100_v2 では上下方向にも非対称性があり、上(上 + up = 1,567)が下(下 + down = 221)を約 7 倍上回る。

考察としては:

- LLM が学習データの中で「方向を 1 つ選ぶ」場面で 右 / 上を default として出しやすいという性質(英語圏の左→右読み、座標系の慣習)が、エージェントの行動選択にそのまま流出している
- 重要なのは、これは prompt で防いでいないだけで、本来は気付いて対策する箇所だったということ。scenario_zero_gravity_5 で 25 倍という極端な比が出ているのは、外的目印(UFO のような)が無いシナリオでは LLM が「とりあえず動く方向」を選ぶ際の左右バイアスが特に強く出るため
- ハッカソン提出物として「LLM の言語側の癖が集団の物理的振る舞いに影響を与える」観察自体は意味がある(prompt と物理が独立だと信じていた仮定の反例)

→ 4.4 節で触れた「reasoning の方向バイアス」(段 2 + 段 3 で緩和)はこの現象の局所表現で、緩和されたとはいえ集団全体の動きとしては今も残っている。34B モデルでの再評価で消えるか / 残るかが比較軸 4 のサブ観点として加わる。

5.12 観察の限界

本章の創発は **Qwen3 4B abliterated** での観察である。以下の現象は 4B モデルの確率的揺らぎ・容量限界の影響を含む可能性がある:

- echo_max=1.000(完全コピペループ)が 5 体・100 体の両方で観察された
- self_similarity が 100 体ランで 0.717 と高め
- 専門知識の混線(A4 のドローン → 看護)

→ 34B モデル(粉川氏マシン)での再評価で「これらの現象が消えるかどうか」が比較軸 4 の主観点となる。

6 頑張った点

審査員に伝えたいのは、技術スタックの自慢ではなく「何を考え、何を試し、何を捨てたか」。

6.1 比較設計の枠組み

「LLM が動くシミュレーション」を作るのは難しくない。難しいのは何を比較すれば創発の差が見えるかの設計である。本プロジェクトでは以下の 4 軸を独立に動かせるよう config 化した:

1. LLM モデル(Qwen3 / Llama / Dolphin)
2. 男女比(0% / 25% / 50% / 75% / 100%)
3. 人種・出身地(日本 / 米国 / 中国 / 混合)
4. 年齢層(若年 / 中年 / 高齢 / 混合)

各軸は他軸を固定して動かすため、組み合わせ爆発を避けつつ「この変化はこの軸が原因だ」と切り分けられる設計にした。

6.2 失敗・没案

6.2.1 100 体ラン v1 の「UFO 言及 0 件」失敗 → 幾何分析で v2 復旧(2026-05-03)

最大の失敗は M-15 で起きた。100 体本番ラン(prod_v3_alien_100)を 8 時間 34 分かけて完走させたが、結果は 30 step 中 UFO 言及が 0 件。発話 3,705 件すべてが日常会話で、誰一人 UFO を話題にしなかった。

原因は 段 3 の知覚距離設定にあった:

項目	v1(失敗)	v2(成功)	理由
events.alien.center_x, center_y	(-55, 45)	(-50, 30)	office 左壁から 10 m。左壁沿いの人が確実に Mid 圏
events.alien.near_radius	8.0	20	office カバレッジ ~5%(左壁近傍 ~5 体が詳細視認)
events.alien.visible_radius	18.0	60	office カバレッジ ~41%(直接知覚 ~40 体)

幾何分析で原因を特定した:

distance(office最角(-40,40), UFO(-55,45)) = sqrt(15² + 5²) ≈ 15.81 m
visible_radius = 18 → 角の数体だけがギリギリ Mid 圏
さらに communication_radius = 5 m → 視認した数体が他者へ伝播できない
結果:office カバレッジ ~3%、95+ 体が UFO を知らないまま 30 step 経過

5 体ランで成功した同じ visible_radius=18 を 100 体に流用したのが直接原因。5 体ランでは office が 20×20 m で carbeit カバレッジが 52% だったが、100 体ランでは office が 80×80 m に拡大しており、同じ 18 m では覆える範囲が ~3% に縮小していた。

教訓:5 体パラメータの 100 体への流用は要慎重。通信半径・知覚距離の絶対値が空間スケールにより意味を変えるため、office カバレッジ率(%)で揃えるのが筋。

v2 で visible_radius を 60 m に拡大し、office カバレッジを 41% に揃えたところ、UFO 言及がピーク 39 体まで回復し、本提出物の主役素材となる「3 層構造の創発」「A5 専門家化」を観察できた(5 章参照)。

6.2.2 動画可視化:100 体ラン用に Spotlight モードを追加(2026-05-04)

prod_v3_alien_100_v2 の動画(simulation_with_text.mp4)を最初に生成したとき、思考パネルに 100 体ぶんの reasoning を固定スロットで並べていた。結果、1 スロットあたり高さが約 0.4% しか取れず、文字が潰れて読めなくなった。

次の改善を入れた:

1. Spotlight モードを追加:現 step に発話/受信に関わった agent + 直近活動が高い agent を上位 5 体だけ表示。残りは「他 95 名は表示省略(うち今 step に思考あり: N 名)」のフッタで明示
2. スロット数を --thought-top で動的に切り替え(5 体ラン → 全員表示、100 体ラン → spotlight 自動切替、auto モード)
3. 思考欄に LLM が JSON action を入れてきたケース({"action": "move", "direction": "up", ...})は正規表現で → move(up) | メモ要約に整形(JSON が途中で切れていても救出する実装)
4. スロット間に薄い区切り線、フォント拡大、DPI 110 → 140

→ 「100 体ラン用の可視化」と「5~10 体ランの可視化」が同じツール 1 本で両立するようになった。動画 1 本で会話の流れと内面が同時に追えるという狙いを 100 体スケールでも達成。

実装: [tools/generate_video_with_text.py](#) / スキル: [.claude/skills/simulation-video/](#)

6.2.3 ZeroGravityEvent 半径 5 m → 8 m への再走(2026-05-02)

zero_gravity 5 体ランの初回(半径 5 m)で 16 件しかメッセージが生成されなかった。原因は無重力イベントが「外的目印を持たない内的事象」のため動く動機が弱く、半径 5 m 圏内に他者がいない時間が支配的になったこと。

→ 半径 8 m に拡大して再走(alien_5 とは条件が違うが、本シナリオに最適化)。結果メッセージ総数が 16 → 142 に 9 倍に増加。提出物では「イベント種類に最適化したパラメータで観察した」と明示している。

教訓:イベントの種類が空間ダイナミクスに与える影響は事前に予測できない。複数シナリオを同じ通信半径で揃えるより、シナリオごとに発話量が一定以上出る半径に最適化する方が観察対象として有用。

6.2.4 abilitated を選ぶまでの遠回り

- 当初は 日本語性能優先で JP 系モデル(ELYZA、Stockmark など)を本命視した

- しかし JP 系には **uncensored** 版が存在しないことを LLM 選定 04 節で確認
- 通常モデルでは「嘘」「派閥」「反乱」が拒否されて発生しないことが小規模実験で判明
- 議論の末、**abliterated** 系(huihui_ai/*)を採用。日本語は Qwen3 でカバー
- 詳細: [docs/01_設計書/02_LLMモデル/2026-04-24_選定と推奨/04_選定の前提.md](#)

6.2.5 VOICEVOX/ずんだもん通知の試行錯誤

- Stop hook で作業終了を音声通知する仕組みを作った
- 最初は Windows 標準 **System.Speech** → 音声がモノトーンで微妙
- VOICEVOX HTTP API + ずんだもん切替 → 起動忘れで聞こえない問題
- 最終的に 手動起動を許容 + フックは silent fail
- ハッカソン本番への教訓: 作業効率改善ツールにはフォールバック必須

6.2.6 6GB VRAM への現実適応

- 当初「7B~14B でいける」と楽観 → 6GB では Q4 でもギリギリ
- KV cache、ctx 長、並列度を全部削って 3~4B + Q4_K_M に着地
- API 併用案(API代替案)も保険として残した

6.2.7 議事録 → 要件定義 → システム設計の 3 段階分割

- 議事録の論点を最初から要件定義に落とそうとして崩壊しかけた
- 議事録 → アイデア整理 → 要件定義 → システム設計 の 4 段に分けて、各段階で「何が決まり、何が未決か」を明示する形に再構成
- ドキュメント細分化(章 = フォルダ + 節 = ファイル)も同じ理由

6.3 技術的挑戦

- OpenAI 互換 API 一枚化: Ollama / llama-server / API を `base_url` だけで切替可能に
- 5 種類の jsonl 構造化ロギング: 創発分析を後から追加せず、最初から設計に組み込んだ
- 3 階層モデルの責任分離: 1階・2階(プロンプト)と 3階(Python)の境界を引いた

7 未解決課題

ハッカソン提出時点(2026-05-07)で 未解決の項目を、誤魔化さずに列挙する。

7.1 4B モデルでのエコー収束(echo_max=1.000 残存)

段 2(personal_context)+ 段 3(距離依存知覚)で完全コピペループ自体は M-12 prod_v2 から大きく緩和されたが、5 体ランの `zero_gravity` と 100 体ランの両方で `echo_max=1.000` が観察された。100 体 v2 ランの `self_similarity` も 0.717 と高めに残る。

- 仮説:Qwen3 4B abliterated の容量限界(2k context、Q4 量子化)が原因
- 検証案:粉川氏マシンの Qwen3 34B abliterated で同シナリオを再走させ、エコー収束が消えるか確認(MTG 2026-05-03~05-05 後に依頼予定)
- 提出物 v1.2 では 34B 結果を反映予定。今回の提出(v1.1)は 4B での観察に限定

7.2 100 体 × 100 step の長時間ラン

今回の提出で観察したのは 100 体 × 30 step(prod_v3_alien_100_v2、約 8 時間 31 分)まで。100 step まで走らせると約 30 時間かかる見積もりで、私側 RTX 3060 Laptop の連続稼働では時間制約から断念した。100 step 走らせると以下が観察できた可能性がある:

- 「専門家モード」(A5 の電気工事士化)が安定した役割になるか、揺り戻しがあるか
- ハブ(A41 など)の集中度が増し続けるか飽和するか
- UFO 言及エージェント数の漸減カーブが「忘却」に達するか

これも粉川氏 34B マシン側で実行依頼予定。

7.3 100 体 × 無重力イベントの未実施

無重力イベント(ZeroGravityEvent)は 5 体ラン(prod_v3_zero_gravity_5)のみ実施した。100 体規模で同イベントを走らせれば、宇宙人(外的目印あり)の場合と異なる伝播パターン(全員に同時に降りかかる「内的事象」の集団反応)が観察できた可能性がある。100 体ラン 1 本につき約 9 時間を要するため、提出までに優先度を宇宙人イベントに絞って 1 本に集約した。

7.4 ZeroGravityEvent の段 3 距離依存化が未実装

AlienEvent は near/visible/far の 3 帯で perceived_info を切り替える段 3 を実装したが、ZeroGravityEvent は全エージェントに同じ prompt_text を配信したまま。本来「無重力は局所現象ではない」性質のため、距離で切り替えるのは不自然という判断で保留した。

- 未解決:無重力でも「気付くか / 気付かないか」「気付き方が個人によって違うか」を分化させる方法
- 候補:personal_context 依存(運動神経・体調)で気付き遅延を入れる、など

7.5 統計的有意性の不足

各構成 1 回ずつの本番ランで観察した内容を提出物にしている。本来は構成あたり 3~10 回の試行で創発の差を「有意に」見たいが、6GB VRAM × 4B モデル × 30 step で 1 ラン 8 時間以上かかるため断念した。

- 改善案:5 体ランは複数 seed で 3 回ずつ走らせて分布を取る(部分実施可能)
- 100 体は粉川氏マシン側で複数 seed 実行を依頼

7.6 ペルソナの社会通念バイアス

personal_contexts_pool 16 件は人間が手書きしたバイアスを含む。「子持ちパパ = 焦り」「新婚 = マンション購入」など、LLM が学習した社会通念を強化する方向に書かれている可能性がある。これは観察対象でもあるが、独立変数として扱うには注意が必要。

- 改善案:同じ人物属性で personal_context を「無記述」にした対照群と差分を見る(時間切れ)

7.7 創発指標の主観性

「派閥」「役割分化」の判定は目視 + ヒューリスティック(発話キーワード集計、受信件数 top-K、3 層構造のステップ別分類)に依存している。自動判定の精度は十分ではなく、目視での誤分類が混じっている可能性は否定できない。

- 改善案:別 LLM(あるいは人間)による独立アノテーションでラベルを付け直す
- 部分実施:今回の提出では生ログ抜粋を主役に置くことで、読者が直接判断できる形にしている

7.8 動画(MP4)の網羅性

提出 MP4 は `prod_v3_alien_100_v2` を主役として収録したが、5 体ラン 2 本(`alien_5 / zero_gravity_5`)も並べたい部分がある。今回の提出では 100 体ランを優先し、5 体ランの動画は GitHub リポジトリ側で参照する形にとどまる。

7.9 tok/s / VRAM ピークの厳密測定

完走時間と発話総数は記録したが、1 step あたりの正確な tok/s や VRAM ピークの継続的測定は未実装。今回の提出では「8 時間 31 分で 100 体 × 30 step が完走した」という事実を載せるに留まる。

- 改善案: `runs/<タイムスタンプ>/perf.jsonl` を毎 step 出力する instrumented run の整備(時間切れ)

7.10 粉川氏マシン引き渡しと 34B 本番

最終的な提出物 v1.2 は 粉川氏マシン側の 34B 本番ランの結果を反映する想定。MTG(2026-05-03～05-05)で:

- `personal_contexts_pool` の最終確定
- 100 体 × 100 step × 34B abliterated の本番依頼
- 提出物 PDF v1.2 の章構成すり合わせ

を実施し、提出締切 2026-05-07 に間に合わせる。今回の提出(v1.1)は 私側 4B で取得できた限界までの観察記録である。

8 今後の展望

8.1 他シナリオへの拡張

3 階層フレームワークは、1 階(物)を入れ替えるだけで別の題材に転用できるように設計してある。優先度の高い拡張先:

シナリオ	1 階	2 階	3 階	観察したい創発
細胞	細胞器官・栄養	組織・血流	拡散・分裂	自己組織化、がん化
虫	体・触角・フェロモン	巣・餌場	重力・風	スウォーム、分業
人(現行)	身体・所持物	場所・天候	通信・近傍	嘘・派閥・通貨
ウイルス	表面タンパク・RNA	宿主・免疫系	拡散・変異	株間競争、エスケープ

参考: [docs/01_設計書/06_システム設計/07_拡張計画/](#)

8.2 モデル拡張

- API ハイブリッド(Claude Haiku / Gemini Flash / Grok)で大集団を回す経路は実装済みだが本番未投入
- MoE 系(Mixtral 等)で「専門家エージェント」を表現する案

8.3 規模拡張

- 100 人 → 1000 人。VRAM/帯域の支配項が変わるため設計から見直し
- マルチノード(別 PC 2 台で半分ずつ受け持つ)の検証

8.4 公開プラン

- リポジトリ: <https://github.com/Kai-85-git/singulab>
- 実行ログサンプル + 解析スクリプトを公開予定
- 「設計の議論経緯ごと」公開する(議事録・要件定義・LLM 選定検討も含む)。失敗例こそ価値があるという立場